
Universidad Nacional de Ingeniería

Facultad de Ciencias

Maestría en Ciencia de la Computación

MCC002 — PROBABILIDAD Y ESTADÍSTICA COMPUTACIONAL

Riesgo y Predicción Cuantitativa

Análisis Predictivo del Statlog German Credit Data

Trabajo	Trabajo Práctico Final Integrador
Equipo	Grupo 5
Integrantes	Armando Castro Chaupis Henry Sánchez Alvarado Alex Segura Núñez
Docente	Dra. Rocío Milagros Zorrilla Coz
Periodo	Periodo Académico 2026-1

Lima, Perú — 2026

Resumen

Este informe estudia los factores asociados con la clasificación de un solicitante como mal riesgo crediticio mediante el conjunto *Statlog German Credit Data*. El análisis integra estadística descriptiva, inferencia frecuentista, regresión lineal y logística, evaluación predictiva bajo costos asimétricos e inferencia bayesiana. El objetivo es producir conclusiones cuantitativas defendibles sobre la tasa de mal crédito, las diferencias entre perfiles de solicitantes y el efecto del umbral de decisión sobre la clasificación. Las estimaciones y visualizaciones se generan de forma reproducible desde el notebook del proyecto.

Palabras clave: riesgo crediticio; regresión logística; costos asimétricos; inferencia frecuentista; inferencia bayesiana; German Credit Data.

Índice

Resumen	I
Índice de figuras	III
Índice de tablas	1
1. Introducción y pregunta de investigación	1
1.1. Pregunta central	1
1.2. Preguntas secundarias	2
1.3. Objetivo general	2
1.4. Objetivos específicos	2
1.5. Alcance del análisis	3
2. Descripción y citación del dataset	3
2.1. Fuente y propósito original	3
2.2. Estructura general	3
2.3. Archivos disponibles y versión utilizada	4
2.4. Variable de clasificación	5
2.5. Matriz de costos	5
2.6. Licencia, acceso y reproducibilidad	6
2.7. Pertinencia y alcance del conjunto de datos	6
3. Diccionario de variables	6
3.1. Clasificación estadística de las variables	7
3.2. Diccionario completo	7
3.3. Variables derivadas para el análisis	9
3.4. Consideraciones de interpretación	9
4. Limpieza y preprocesamiento	10
4.1. Configuración reproducible	10
4.2. Localización y carga del archivo	11
4.3. Conservación de los códigos originales	11
4.4. Verificaciones de integridad	12
4.5. Recodificación de la variable respuesta	13
4.6. Tratamiento de categorías informativas	13
4.7. Transformación del monto	14
4.8. Separación entre preprocesamiento y modelamiento	14

4.9. Resultado del preprocesamiento	14
5. Análisis exploratorio	15
5.1. Distribución de la variable respuesta	15
5.2. Propósito del préstamo	15
5.3. Duración del crédito	16
5.4. Monto del crédito	17
5.5. Edad del solicitante	17
5.6. Carga de la cuota	17
5.7. Relaciones monotónicas entre variables	18
5.8. Síntesis exploratoria	18
6. Estadística descriptiva	19
6.1. Resumen de las variables numéricas	20
6.2. Forma de la distribución del monto	20
6.3. Descriptivos por clase de riesgo	21
6.4. Ajuste paramétrico del monto mediante máxima verosimilitud	21
6.5. Comparación mediante log-verosimilitud y AIC	22
6.6. Implicancias para los análisis posteriores	23
7. Visualizaciones	24
7.1. Criterios de presentación	24
7.2. Composición de la cartera	24
7.3. Tasa de mal crédito por propósito	25
7.4. Duración y monto según la clase	26
7.5. Asociaciones monotónicas	27
7.6. Ajuste paramétrico del monto	28
7.7. Ubicación de las visualizaciones especializadas	29
8. Análisis de incertidumbre frecuentista	30
8.1. Proporción observada de malos créditos	30
8.2. Intervalo analítico de Wilson	31
8.3. Intervalo bootstrap percentil	31
8.4. Comparación de los intervalos para la proporción	32
8.5. Intervalo para la duración media	33
8.6. Interpretación frecuentista	33
8.7. Supuestos y alcance	34
9. Inferencia estadística frecuentista	34

9.1. Asociación entre propósito y clase de riesgo	35
9.1.1. Verificación de las frecuencias esperadas	36
9.2. Magnitud de la asociación: V de Cramér	37
9.3. Categorías que contribuyen a la asociación	37
9.4. Comparación de la duración	38
9.5. Tamaño del efecto de la duración	39
9.6. Comparación del monto	40
9.7. Tamaños del efecto del monto	40
9.8. Resumen de los contrastes	41
9.9. Interpretación integrada de la evidencia frecuentista	42
9.10. Supuestos y limitaciones	43
10. Modelo de regresión y diagnóstico	43
10.1. Regresión lineal múltiple para el monto del crédito	43
10.1.1. Especificación del modelo	44
10.1.2. Ajuste global	44
10.1.3. Coeficientes estimados	45
10.2. Diagnóstico de multicolinealidad	46
10.3. Diagnóstico gráfico de los residuos	47
10.4. Normalidad de los residuos	48
10.5. Homocedasticidad: prueba de Breusch–Pagan	48
10.6. Inferencia robusta HC3	49
10.7. Validación cruzada de cinco particiones	49
10.8. Conclusión del modelo lineal	50
10.9. Regresión logística para la probabilidad de mal crédito	51
10.9.1. Diseño de entrenamiento y prueba	51
10.9.2. Especificación del modelo	52
10.10 Interpretación mediante odds ratios	53
10.10.1. Predictores numéricos	53
10.10.2. Categorías con evidencia estadística	54
10.11 Capacidad discriminativa	55
10.12 Validación cruzada del modelo logístico	56
10.13 Clasificación con el umbral estándar	57
10.14 Selección del umbral bajo costos asimétricos	58
10.15 Comparación de las políticas de decisión	59
10.16 Lectura operativa del modelo	61
10.17 Conclusión del modelamiento	62

11. Análisis bayesiano	62
11.1. Modelo Beta–Binomial para la tasa de mal crédito	63
11.1.1. Verosimilitud binomial	63
11.1.2. Distribución previa Beta	64
11.1.3. Posterior conjugada	64
11.2. Resúmenes de la distribución posterior	65
11.2.1. Media posterior	65
11.2.2. Estimación MAP	65
11.2.3. Intervalo creíble	65
11.3. Distribuciones previas evaluadas	65
11.3.1. Prior uniforme	65
11.3.2. Prior de Jeffreys	66
11.3.3. Prior informativo débil	66
11.4. Resultados posteriores	67
11.5. Sensibilidad al prior	67
11.6. Comparación con la inferencia frecuentista	68
11.7. Supuestos y alcance del modelo	69
11.8. Regresión logística bayesiana	70
11.9. Especificación probabilística	70
11.10 Necesidad de simulación MCMC	71
11.11 Sampler random-walk Metropolis–Hastings	72
11.11.1. Estado inicial	72
11.11.2. Distribución de propuesta	72
11.11.3. Regla de aceptación	73
11.12 Configuración de la simulación	74
11.13 Diagnóstico de la cadena	74
11.14 Posterior del coeficiente de duración	75
11.15 Interpretación mediante odds ratio	76
11.16 Comparación con la estimación frecuentista	77
11.17 Evaluación crítica del sampler	78
11.18 Conclusión del análisis bayesiano	78
12. Interpretación integrada	79
12.1. Respuesta a la pregunta central	79
12.2. Diferencia entre asociación marginal y condicional	80
12.3. Propósito del préstamo como factor de segmentación	81
12.4. Síntesis de la evidencia por factor	81

12.5. Respuesta a las preguntas secundarias	82
12.5.1. ¿Cuál es la proporción global de malos créditos?	82
12.5.2. ¿La tasa difiere según el propósito?	83
12.5.3. ¿La duración y el monto difieren entre las clases?	83
12.5.4. ¿Qué variables están asociadas con mayor riesgo?	83
12.5.5. ¿Cómo cambia la clasificación al modificar el umbral?	84
12.6. Coherencia entre los enfoques estadísticos	84
12.7. Predicción y utilidad operativa	85
12.8. Implicancias para una política crediticia	86
12.9. Respuesta integrada final	86
13. Limitaciones y validez	87
13.1. Validez interna	87
13.2. Validez de constructo	88
13.2.1. Definición de mal riesgo	88
13.2.2. Variables ordinales	88
13.2.3. Categorías ambiguas	88
13.3. Sesgo de selección	89
13.4. Validez predictiva	89
13.4.1. Partición aleatoria	90
13.4.2. Tamaño del conjunto de prueba	90
13.4.3. Calibración	90
13.5. Especificación del modelo	91
13.6. Variables omitidas	91
13.7. Categorías poco frecuentes	92
13.8. Multiplicidad e interpretación de significancia	92
13.9. Validez externa	93
13.10 Validez operativa y matriz de costos	93
13.11 Equidad y variables sensibles	94
13.12 Riesgo de automatización	95
13.13 Limitaciones del análisis OLS	95
13.14 Limitaciones del análisis bayesiano	95
13.15 Reproducibilidad y dependencia computacional	96
13.16 Resumen de limitaciones	97
13.17 Alcance válido de las conclusiones	97
14. Conclusiones	98
14.1. Conclusiones principales	98

15. Declaración de contribución individual	101
15.1. Responsabilidades compartidas	102
15.2. Responsabilidad académica	103
A. Declaración de uso de inteligencia artificial	104
B. Reproducibilidad	106
B.1. Entorno computacional	106
B.2. Datos y configuración	106
B.3. Ejecución del notebook	107
B.4. Resultados esperados	107
B.5. Compilación del informe	108
B.6. Criterio de reproducibilidad	108

Índice de figuras

1.	Distribución de los registros según la clase de riesgo crediticio.	25
2.	Tasa observada de mal crédito según el propósito del préstamo. La línea de referencia representa la tasa global de la cartera.	26
3.	Distribución de la duración y el monto del crédito según la clase de riesgo.	27
4.	Matriz de correlaciones de Spearman entre las variables cuantitativas y ordinales del análisis.	28
5.	Ajuste paramétrico del monto del crédito. El panel izquierdo compara las densidades Lognormal y Gamma con el histograma observado; el panel derecho evalúa la normalidad aproximada del logaritmo del monto mediante un gráfico Q–Q.	29
6.	Diagnósticos del modelo OLS para $\log(\text{monto})$: residuos frente a valores ajustados, gráfico Q–Q, gráfico Scale–Location y residuos estandarizados frente a leverage.	47
7.	Odds ratios e intervalos de confianza del 95 % del modelo logístico. La línea vertical representa ausencia de asociación en la escala de odds ratios.	55
8.	Costo total de clasificación en el conjunto de prueba según el umbral. Se muestran el umbral estándar, el umbral teórico derivado de la matriz 5 : 1 y el mínimo empírico.	59
9.	Curva ROC y matrices de confusión del modelo logístico con el umbral estándar y el umbral derivado de la matriz de costos.	61
10.	Sensibilidad del modelo Beta–Binomial a la elección del prior. El panel izquierdo muestra las tres distribuciones previas. El panel derecho presenta las posteriores, la estimación frecuentista y el intervalo de Wilson del 95 %.	68
11.	Diagnóstico del sampler Metropolis–Hastings para el coeficiente de duración. El panel izquierdo muestra la traza completa y el final del burn-in. El panel derecho compara la posterior marginal simulada con la aproximación normal basada en el MLE.	75

Índice de cuadros

1.	Características generales del conjunto de datos.	4
2.	Matriz de costos asociada con la clasificación crediticia.	5
3.	Clasificación de las variables predictoras según su naturaleza estadística. . .	7
4.	Diccionario de variables del conjunto <i>Statlog German Credit Data</i>	7
5.	Variables derivadas utilizadas en el análisis.	9
6.	Entorno computacional registrado por el notebook.	10
7.	Verificaciones de integridad aplicadas al dataset.	12
8.	Tasa observada de mal crédito según el propósito del préstamo.	16
9.	Síntesis de los principales patrones exploratorios.	19
10.	Estadística descriptiva de las variables numéricas.	20
11.	Estadística descriptiva de las variables principales según la clase de riesgo. .	21
12.	Comparación de los ajustes Lognormal y Gamma para el monto del crédito. .	23
13.	Ubicación de las visualizaciones especializadas dentro del informe.	29
14.	Intervalos de confianza del 95 % para la proporción de malos créditos. . . .	32
15.	Resumen de los intervalos de confianza construidos.	33
16.	Frecuencias observadas de la clase de riesgo según el propósito del préstamo.	36
17.	Residuos estandarizados para la clase de mal riesgo según el propósito. . .	38
18.	Resumen de las pruebas de hipótesis y tamaños de efecto.	42
19.	Coeficientes del modelo OLS para el logaritmo del monto.	45
20.	Factores de inflación de la varianza del modelo OLS.	46
21.	Comparación entre la inferencia clásica y la corrección robusta HC3.	49
22.	Resultados de validación cruzada del modelo OLS.	50
23.	Odds ratios de los predictores numéricos del modelo logístico.	53
24.	Categorías con asociación estadísticamente significativa en el modelo logístico.	54
25.	ROC–AUC por partición en la validación cruzada del modelo logístico. . .	57
26.	Desempeño del modelo logístico bajo los umbrales 0.50 y 1/6.	59
27.	Resultados del modelo Beta–Binomial bajo diferentes distribuciones previas.	67
28.	Comparación entre la inferencia frecuentista y bayesiana para la tasa de mal crédito.	69
29.	Configuración del sampler Metropolis–Hastings.	74
30.	Comparación frecuentista y bayesiana del coeficiente de duración.	77
31.	Síntesis integrada de los factores asociados con el riesgo crediticio.	82
32.	Principales limitaciones y sus consecuencias.	97
33.	Distribución de las contribuciones individuales.	102

1 Introducción y pregunta de investigación

La evaluación del riesgo de crédito es una decisión central para las instituciones financieras. Antes de otorgar un préstamo, la entidad debe estimar si el solicitante tendrá capacidad y disposición para cumplir con las obligaciones pactadas. Esta decisión se realiza bajo incertidumbre: personas con perfiles similares pueden presentar comportamientos de pago distintos y la información disponible al momento de la solicitud no permite conocer con certeza el resultado futuro.

Desde una perspectiva de ciencia de datos, el problema consiste en identificar patrones estadísticos que permitan distinguir entre solicitantes con menor y mayor riesgo. Sin embargo, el objetivo no debe reducirse a maximizar la proporción total de clasificaciones correctas. En riesgo crediticio, los errores tienen consecuencias diferentes. Aprobar a un solicitante que posteriormente incumple puede generar pérdidas de capital, costos de cobranza y deterioro de la cartera; rechazar a un solicitante solvente implica perder ingresos potenciales y excluir una operación que pudo haber sido rentable.

Esta asimetría obliga a evaluar los modelos no solo por su capacidad predictiva, sino también por la forma en que sus decisiones cambian al modificar el umbral de clasificación. Por ello, el análisis combina tres niveles complementarios. Primero, se estudian las características de la cartera y las asociaciones marginales entre las variables observadas y la clase de riesgo. Segundo, se construyen modelos que permiten evaluar estas asociaciones de manera conjunta y estimar probabilidades de mal crédito. Tercero, se incorpora una perspectiva de decisión, en la cual el umbral de clasificación se relaciona con el costo desigual de los errores.

El estudio utiliza el conjunto *Statlog German Credit Data*, disponible en el UCI Machine Learning Repository (Hofmann, 1994). El dataset contiene información sobre características financieras, personales y contractuales de solicitantes de crédito, junto con una clasificación final como buen o mal riesgo. Su estructura permite desarrollar un flujo completo de análisis descriptivo, inferencial, predictivo y bayesiano.

1.1 Pregunta central

De acuerdo con la consigna asignada al Grupo 5, la pregunta que orienta el trabajo es:

¿Qué factores explican la probabilidad de que un solicitante sea clasificado como mal riesgo crediticio?

En este informe, el término “explican” se utiliza en un sentido estadístico y predictivo. Las asociaciones identificadas permiten describir cómo cambia la probabilidad estimada de mal crédito cuando varían determinadas características, manteniendo constantes las demás variables incluidas en el modelo. Debido a que se trabaja con datos observacionales, estas asociaciones no deben interpretarse como efectos causales.

1.2 Preguntas secundarias

La pregunta central se desarrolla mediante cinco preguntas específicas:

1. ¿Cuál es la proporción global de malos créditos y cuál es la incertidumbre asociada con su estimación?
2. ¿La tasa de mal crédito difiere según el propósito declarado del préstamo?
3. ¿La duración y el monto del crédito presentan diferencias entre los solicitantes clasificados como buenos y malos riesgos?
4. ¿Qué variables conservan una asociación relevante con el riesgo crediticio cuando se analizan de manera conjunta?
5. ¿Cómo cambia la clasificación de los solicitantes al modificar el umbral de decisión y considerar costos asimétricos?

Estas preguntas conectan la caracterización de la cartera con la inferencia estadística y la evaluación predictiva. Las primeras tres se concentran en proporciones, diferencias entre grupos y asociaciones marginales. La cuarta requiere un modelo multivariable que permita distinguir el efecto condicional de cada predictor. La quinta traslada las probabilidades estimadas a una regla de decisión y evalúa las consecuencias de modificar el punto de corte.

1.3 Objetivo general

Analizar los factores asociados con la probabilidad de mal riesgo crediticio mediante un flujo estadístico reproducible que integre análisis exploratorio, inferencia frecuentista, modelamiento de regresión, evaluación predictiva bajo costos asimétricos e inferencia bayesiana.

1.4 Objetivos específicos

1. Describir la composición del conjunto de datos y documentar la codificación de las variables, en particular la definición de buen y mal riesgo crediticio.
2. Estimar la proporción global de malos créditos y cuantificar su incertidumbre mediante intervalos analíticos y procedimientos de remuestreo.
3. Evaluar la asociación entre la clase de riesgo, el propósito del préstamo y las principales variables cuantitativas, acompañando las pruebas de hipótesis con medidas de tamaño de efecto.
4. Ajustar y diagnosticar modelos de regresión que permitan estudiar relaciones multivariantes y estimar la probabilidad de mal crédito.
5. Evaluar el desempeño del modelo de clasificación mediante métricas discriminativas y operativas, evitando utilizar la exactitud global como único criterio.
6. Comparar el umbral convencional de 0.50 con un umbral justificado mediante una relación de costos asimétrica.
7. Desarrollar un análisis bayesiano de la tasa de mal crédito, incluyendo posterior conjugada, estimación MAP, intervalo creíble y sensibilidad a la elección del prior.

8. Comparar los resultados frecuentistas y bayesianos, e identificar los supuestos y limitaciones que condicionan su interpretación.

1.5 Alcance del análisis

El trabajo tiene un alcance explicativo-asociativo y predictivo. Busca identificar variables que aporten información sobre el riesgo dentro de la muestra analizada y evaluar un procedimiento de clasificación reproducible. No pretende establecer relaciones causales ni proponer un sistema listo para su aplicación directa en una institución financiera.

La antigüedad del dataset, su contexto geográfico y la ausencia de información sobre solicitantes rechazados limitan la generalización de los resultados. Asimismo, una aplicación real requeriría recalibración, validación temporal, evaluación sobre datos externos, revisión de equidad y estimación institucional de los costos económicos asociados con cada tipo de error. Estas restricciones se desarrollan con mayor detalle en la Sección 13.

2 Descripción y citación del dataset

2.1 Fuente y propósito original

El análisis utiliza el conjunto de datos *Statlog (German Credit Data)*, publicado en el UCI Machine Learning Repository y atribuido a Hans Hofmann (Hofmann, 1994). El dataset fue incorporado al repositorio en 1994 y fue diseñado como un problema de clasificación binaria: cada registro representa un perfil crediticio que debe ser clasificado como buen o mal riesgo.

El conjunto pertenece a la familia de problemas *Statlog*, desarrollada para comparar métodos estadísticos y algoritmos de clasificación sobre datos reales. En este caso, el objetivo consiste en utilizar información financiera, contractual y personal disponible al momento de evaluar una solicitud para distinguir entre dos clases de riesgo.

La elección del dataset responde directamente a la consigna asignada al Grupo 5. Su estructura permite estudiar la tasa de mal crédito, comparar grupos de solicitantes, ajustar modelos multivariados y evaluar cómo cambia una decisión cuando se modifica el umbral de clasificación.

2.2 Estructura general

El archivo utilizado contiene 1000 observaciones, 20 variables predictoras y una variable de clasificación. Cada fila corresponde a un registro crediticio y cada columna representa una característica del solicitante o de la operación evaluada.

La estructura general se resume en la Tabla 1.

Cuadro 1: Características generales del conjunto de datos.

Característica	Descripción
Nombre oficial	<i>Statlog (German Credit Data)</i>
Fuente	UCI Machine Learning Repository
Autor o proveedor	Hans Hofmann
Año de publicación	1994
Unidad de análisis	Registro de una operación o perfil crediticio
Número de observaciones	1000
Variables predictoras	20
Variable respuesta	Clasificación como buen o mal riesgo crediticio
Tipo de tarea	Clasificación binaria supervisada
Tipos de variables	Categorías, ordinales y numéricas
Valores faltantes declarados	No
Licencia	Creative Commons Attribution 4.0 International (CC BY 4.0)
Identificador persistente	DOI: 10.24432/C5NC77

La documentación original distingue siete atributos registrados mediante valores numéricos y trece atributos cualitativos representados mediante códigos simbólicos. En el análisis posterior, algunas de las variables numéricas se tratan como ordinales codificadas, debido a que sus valores representan categorías ordenadas y no mediciones continuas.

La descripción detallada de cada predictor, su naturaleza estadística, su unidad y su codificación se presenta en la Sección 3.

2.3 Archivos disponibles y versión utilizada

El repositorio UCI distribuye dos versiones principales del dataset:

- `german.data`, que conserva los códigos simbólicos y categóricos del archivo original;
- `german.data-numeric`, que transforma las categorías en variables indicadoras para facilitar su uso en algoritmos que requieren entradas exclusivamente numéricas.

En este trabajo se utiliza `german.data`. Esta elección permite conservar la semántica original de las categorías y mantener una separación explícita entre variables numéricas, ordinales y nominales. También facilita la interpretación de los coeficientes del modelo y de los perfiles asociados con mayor o menor riesgo.

El archivo está separado por espacios y no contiene una fila de encabezados. Por ello, durante la carga se asignan los nombres de las columnas a partir de la documentación oficial `german.doc`. Una vez incorporados los nombres, la matriz de datos contiene 1000 filas y 21 columnas: veinte predictores y la clase original.

2.4 Variable de clasificación

La variable respuesta original utiliza la siguiente codificación:

$$\text{clase} = \begin{cases} 1, & \text{buen riesgo,} \\ 2, & \text{mal riesgo.} \end{cases}$$

Esta codificación se conserva al cargar el archivo, pero posteriormente se construye una variable binaria denominada `mal\_credito`, en la que el evento de interés se representa mediante el valor uno. La transformación completa y sus implicancias para las métricas de clasificación se explican en la Sección 4.

Es importante distinguir la etiqueta proporcionada por el dataset de un incumplimiento observado en un sistema financiero contemporáneo. La variable expresa la clasificación disponible en la fuente original; por tanto, se utiliza como aproximación operativa al riesgo crediticio dentro de este ejercicio y no como una definición universal de default.

2.5 Matriz de costos

Una característica central del dataset es la inclusión de una matriz de costos. La documentación establece que clasificar como buen riesgo a un solicitante que pertenece a la clase de mal riesgo tiene un costo cinco veces mayor que realizar el error contrario.

La matriz original se presenta en la Tabla 2.

Cuadro 2: Matriz de costos asociada con la clasificación crediticia.

Clase real	Clase predicha	
	Buen riesgo	Mal riesgo
Buen riesgo	0	1
Mal riesgo	5	0

Bajo la recodificación utilizada en este trabajo, el mal crédito es la clase positiva. En consecuencia, aprobar como buen riesgo un caso que realmente pertenece a la clase de mal riesgo corresponde a un falso negativo y recibe un costo de 5. Rechazar o clasificar como riesgoso un caso que realmente era buen crédito corresponde a un falso positivo y recibe un costo de 1.

Esta asimetría se incorpora posteriormente al seleccionar el umbral de decisión. No se utiliza para modificar artificialmente las etiquetas ni para evaluar el modelo únicamente mediante exactitud global.

2.6 Licencia, acceso y reproducibilidad

El dataset se distribuye bajo la licencia Creative Commons Attribution 4.0 International. Esta licencia permite su uso, adaptación y redistribución, siempre que se reconozca adecuadamente la fuente.

Para garantizar la reproducibilidad, el notebook busca primero una copia local en:

`data/german.data`

Si el archivo no existe, el procedimiento descarga el paquete oficial desde UCI, extrae `german.data` y lo almacena en la carpeta `data`. Después de la carga se verifica que la matriz tenga exactamente 1000 observaciones y 21 columnas, y que la variable `clase` contenga únicamente los valores 1 y 2.

Este mecanismo permite ejecutar el notebook desde cero sin depender de una ruta absoluta del equipo local. Las comprobaciones posteriores de integridad, valores faltantes, duplicados, rangos y codificaciones se describen en la Sección 4.

2.7 Pertinencia y alcance del conjunto de datos

El dataset resulta adecuado para el objetivo del trabajo porque combina variables relacionadas con la operación crediticia, la capacidad financiera y algunas características personales del solicitante. Esta diversidad permite contrastar asociaciones marginales, construir modelos multivariantes y analizar la relación entre desempeño predictivo y costo de decisión.

Sin embargo, su uso requiere cautela. La fuente ofrece información limitada sobre el periodo de recolección, el procedimiento de muestreo, las reglas utilizadas para asignar la clase y la población de solicitantes excluidos antes de la aprobación. Tampoco debe suponerse que los patrones observados representan el comportamiento actual de una cartera peruana o de otra institución financiera.

Por estas razones, el dataset se utiliza como un caso académico de análisis estadístico y no como una base suficiente para desplegar un modelo de originación de créditos. Las consecuencias de estas limitaciones para la validez externa, la equidad y el uso responsable se discuten en la Sección 13.

3 Diccionario de variables

El conjunto de datos contiene veinte variables predictoras y una variable de clasificación. Para mantener la trazabilidad entre la fuente, el notebook y el informe, se conservan los códigos originales del archivo `german.data`. Los nombres en español se utilizan como identificadores analíticos y no alteran los valores almacenados en el dataset.

Esta decisión resulta importante porque varias columnas no representan mediciones continuas, aunque estén registradas mediante números. Por ejemplo, `tasa_cuota` y `anios_residencia` utilizan valores enteros de 1 a 4, pero estos valores identifican niveles ordenados y no cantidades observadas directamente. Del mismo modo, códigos como `A65` y `A124` corresponden a categorías válidas y no deben interpretarse como valores faltantes.

3.1 Clasificación estadística de las variables

La clasificación utilizada en el notebook se resume en la Tabla 3.

Cuadro 3: Clasificación de las variables predictoras según su naturaleza estadística.

Grupo	Cantidad	Variables
Numéricas discretas	5	duracion, monto, edad, n_creditos_banco y n_dependientes.
Ordinales codificadas	2	tasa_cuota y anios_residencia.
Categóricas	13	Estado de cuenta, historial crediticio, propósito, ahorros, empleo, estatus personal, otros deudores, propiedad, otros planes de pago, vivienda, trabajo, teléfono y condición de trabajador extranjero.
Variable respuesta original	1	clase.

Esta clasificación responde al uso analítico de las variables. No implica que todas las categorías ordenadas deban introducirse como variables lineales en los modelos. La forma de codificación depende del propósito de cada análisis y se documenta en las secciones correspondientes.

3.2 Diccionario completo

La Tabla 4 presenta el nombre utilizado en el notebook, el tipo estadístico y la codificación de cada atributo.

Cuadro 4: Diccionario de variables del conjunto *Statlog German Credit Data*.

#	Variable	Tipo	Descripción y codificación
1	estado_cuenta	Categórica ordinal	Estado de la cuenta corriente: A11, saldo menor que 0 DM; A12, saldo entre 0 y 200 DM; A13, saldo igual o mayor que 200 DM; A14, sin cuenta corriente.
2	duracion	Numérica discreta	Duración contractual del crédito, expresada en meses.
3	historial_credito	Categórica	Historial de cumplimiento: A30, sin créditos previos o todos pagados; A31, créditos de este banco pagados correctamente; A32, créditos existentes al día; A33, retrasos en pagos anteriores; A34, cuenta crítica o créditos en otras entidades.
4	proposito	Categórica nominal	Finalidad del préstamo: A40, auto nuevo; A41, auto usado; A42, mobiliario o equipos; A43, radio o televisión; A44, electrodomésticos; A45, reparaciones; A46, educación; A48, reentrenamiento; A49, negocio; A410, otros propósitos.
5	monto	Numérica discreta	Monto del crédito, expresado en marcos alemanes (DM).

Continúa en la página siguiente

Continuación de la Tabla 4

#	Variable	Tipo	Descripción y codificación
6	ahorros	Categórica ordinal	Nivel de ahorros o bonos: A61, menos de 100 DM; A62, entre 100 y 500 DM; A63, entre 500 y 1000 DM; A64, 1000 DM o más; A65, nivel desconocido o sin cuenta de ahorros.
7	empleo_actual	Categórica ordinal	Antigüedad en el empleo actual: A71, desempleado; A72, menos de un año; A73, entre uno y cuatro años; A74, entre cuatro y siete años; A75, siete años o más.
8	tasa_cuota	Ordinal codificada	Nivel de la cuota del crédito respecto del ingreso disponible. Utiliza valores de 1 a 4. Se interpreta como una escala ordenada de carga financiera, no como el porcentaje exacto observado.
9	estatus_personal	Categórica sensible	Variable histórica que combina sexo y estado personal: A91, hombre divorciado o separado; A92, mujer divorciada, separada o casada; A93, hombre soltero; A94, hombre casado o viudo. No permite separar limpiamente sexo y estado civil.
10	otros_deudores	Categórica nominal	Participación de terceros: A101, ninguno; A102, co-solicitante; A103, garante.
11	anios_residencia	Ordinal codificada	Antigüedad en la residencia actual. Se registra mediante una escala ordenada con valores de 1 a 4.
12	propiedad	Categórica nominal	Principal forma de patrimonio declarada: A121, bienes inmuebles; A122, ahorro para vivienda o seguro de vida; A123, automóvil u otra propiedad; A124, propiedad desconocida o inexistente.
13	edad	Numérica discreta	Edad del solicitante, expresada en años.
14	otros_planes_pago	Categórica nominal	Otros planes de pago a plazos: A141, banco; A142, tiendas; A143, ninguno.
15	vivienda	Categórica nominal	Régimen de vivienda: A151, alquilada; A152, propia; A153, gratuita.
16	n_creditos_banco	Numérica discreta	Número de créditos existentes del solicitante en esta entidad bancaria. En los datos toma valores entre 1 y 4.
17	trabajo	Categórica	Situación ocupacional: A171, desempleado o trabajador no calificado no residente; A172, trabajador no calificado residente; A173, trabajador calificado o empleado; A174, directivo, independiente o trabajador altamente calificado.
18	n_dependientes	Numérica discreta	Número de personas económicamente dependientes del solicitante. En el archivo toma los valores 1 o 2.
19	telefono	Categórica binaria	Disponibilidad de teléfono registrado a nombre del solicitante: A191, no; A192, sí.
20	trabajador_extranjero	Categórica binaria sensible	Condición de trabajador extranjero: A201, sí; A202, no.
21	clase	Respuesta original	Clasificación proporcionada por el dataset: 1, buen riesgo; 2, mal riesgo.

3.3 Variables derivadas para el análisis

El notebook construye tres variables adicionales. Estas columnas no forman parte del archivo original, sino que se generan durante el preprocesamiento para facilitar el análisis y la presentación de los resultados.

Cuadro 5: Variables derivadas utilizadas en el análisis.

Variable	Tipo	Definición
mal_credito	Binaria	Variable respuesta del análisis: 0 = buen riesgo y 1 = mal riesgo.
clase_lbl	Categorica ordenada	Etiqueta legible de la respuesta: “Buen riesgo” o “Mal riesgo”. Se utiliza en tablas y figuras.
log_monto	Numérica continua	Logaritmo natural del monto: $\log(\text{monto})$. Se utiliza para reducir la asimetría y estabilizar la escala en determinados modelos.

La respuesta binaria queda definida formalmente como:

$$Y_i = \begin{cases} 0, & \text{si } \text{clase}_i = 1 \quad (\text{buen riesgo}), \\ 1, & \text{si } \text{clase}_i = 2 \quad (\text{mal riesgo}). \end{cases}$$

Esta recodificación sitúa al mal crédito como clase positiva. En consecuencia, el *recall* mide la proporción de créditos de mal riesgo que el modelo consigue identificar. También permite expresar directamente como falso negativo el error de clasificar un mal crédito como buen riesgo, que es el error de mayor costo en la matriz definida por el dataset.

3.4 Consideraciones de interpretación

El diccionario contiene variables que requieren especial cautela. En particular, `estatus_personal_sexo` combina dos características en una sola codificación histórica, mientras que `trabajador_extranjero` representa una condición potencialmente sensible. Estas variables no deben interpretarse como causas del riesgo ni utilizarse para justificar decisiones individuales sin una revisión de equidad, regulación y pertinencia operacional.

Asimismo, las categorías “desconocido” o “sin cuenta” no se reemplazan por valores faltantes. En un proceso de originación, la falta de una cuenta o de información documentada puede constituir una señal observable del perfil evaluado. Sin embargo, agrupar ambas situaciones en un solo código limita la interpretación: no es posible determinar si el solicitante carecía del producto financiero o si la información simplemente no estaba disponible.

Estas restricciones serán consideradas al interpretar las asociaciones marginales y los coeficientes de los modelos, evitando atribuir un significado más preciso del que permite la documentación original.

4 Limpieza y preprocesamiento

El preprocesamiento tuvo como propósito construir una base analítica consistente sin alterar innecesariamente la información original. El procedimiento se diseñó para ser reproducible, de modo que el notebook pueda ejecutarse desde el inicio tanto si el dataset ya se encuentra en el repositorio como si debe descargarse desde la fuente oficial.

A diferencia de otros problemas aplicados, el conjunto de datos no requirió imputación, eliminación de registros ni corrección manual de categorías. El trabajo se concentró en verificar la integridad de la fuente, documentar la codificación de la respuesta, conservar la naturaleza estadística de los predictores y construir las variables derivadas necesarias para el análisis.

4.1 Configuración reproducible

Al inicio del notebook se fija una semilla global:

SEED = 2026.

La semilla se utiliza en los procedimientos que dependen de generación pseudoaleatoria, entre ellos el remuestreo bootstrap, la separación de datos, la validación cruzada y el sampler Metropolis–Hastings. Su uso permite reproducir las principales estimaciones obtenidas durante el análisis.

El entorno utilizado corresponde a Python 3.12.10. Las versiones registradas durante la ejecución se presentan en la Tabla 6.

Cuadro 6: Entorno computacional registrado por el notebook.

Componente	Versión
Python	3.12.10
NumPy	2.4.6
pandas	3.0.3
SciPy	1.17.1
statsmodels	0.14.6
scikit-learn	1.9.0
seaborn	0.13.2

Las dependencias del proyecto se registran adicionalmente en el archivo `requirements.txt`. Esta separación entre código, datos, resultados y dependencias reduce la dependencia del entorno local desde el cual se ejecuta el análisis.

4.2 Localización y carga del archivo

El notebook no utiliza una ruta absoluta fija. En su lugar, busca la raíz del repositorio recorriendo el directorio actual y sus directorios superiores hasta encontrar la carpeta `.git` o el archivo `README.md`. A partir de esa ubicación se define la ruta:

`data/german.data`

Si el archivo no se encuentra localmente, el procedimiento descarga el paquete comprimido desde UCI, verifica que contenga `german.data`, lo extrae y lo almacena en la carpeta `data`. De esta manera, el notebook puede ejecutarse sin depender de una copia manual ubicada fuera del proyecto.

El archivo original está separado por espacios y no contiene nombres de columnas. Durante la lectura se asignan los veintidós nombres definidos en el diccionario de variables: veinte predictores y la clase original.

Después de la carga se comprueba que la matriz tenga exactamente:

1000 observaciones $\times$ 21 columnas.

La ejecución se detiene mediante una excepción si las dimensiones no coinciden con la documentación o si la variable `clase` contiene valores diferentes de 1 y 2.

4.3 Conservación de los códigos originales

Las variables categóricas se mantienen con sus códigos originales, por ejemplo A11, A34 o A65. Esta decisión conserva la trazabilidad con la documentación de UCI y evita modificar la información antes de definir el uso de cada predictor.

Para facilitar la lectura de tablas y visualizaciones se generan etiquetas en español para cuatro variables especialmente relevantes:

- propósito del crédito;
- estado de la cuenta corriente;
- nivel de ahorros;
- historial crediticio.

Las nuevas columnas utilizan el sufijo `_lbl`. Por ejemplo, `proposito_lbl` contiene descripciones como “Auto nuevo”, “Educación” o “Negocio”, mientras que `proposito` conserva códigos como A40, A46 o A49.

Antes de construir cada etiqueta, el notebook compara los códigos observados con las claves disponibles en el diccionario correspondiente. La ejecución se detiene si aparece una categoría sin mapear. Esta validación evita que un código inesperado se convierta silenciosamente en un valor faltante.

4.4 Verificaciones de integridad

Las comprobaciones aplicadas a las variables originales se resumen en la Tabla 7.

Cuadro 7: Verificaciones de integridad aplicadas al dataset.

Verificación	Criterio	Resultado
Valores faltantes	Total igual a 0	Cumple
Filas completamente duplicadas	Total igual a 0	Cumple
Duración	Mayor que 0	Cumple
Monto	Mayor que 0	Cumple
Edad	Entre 18 y 100 años	Cumple
Tasa de la cuota	Valores en {1, 2, 3, 4}	Cumple
Antigüedad en la residencia	Valores en {1, 2, 3, 4}	Cumple
Número de créditos en el banco	Valores en {1, 2, 3, 4}	Cumple
Número de dependientes	Valores en {1, 2}	Cumple
Clase original	Valores en {1, 2}	Cumple
Respuesta recodificada	Valores en {0, 1}	Cumple

Las verificaciones no detectaron valores faltantes ni filas completamente duplicadas. Asimismo, las variables numéricas y ordinales se encontraron dentro de los rangos documentados. Por esta razón, no fue necesario eliminar observaciones, imputar datos ni corregir categorías.

No se eliminaron valores extremos de duración o monto. Aunque algunas observaciones se encuentran alejadas del centro de sus distribuciones, corresponden a registros válidos del dataset y pueden representar operaciones crediticias reales. Su influencia se examina mediante estadística descriptiva, visualizaciones, transformaciones y diagnósticos de los modelos, en lugar de descartarlas automáticamente.

4.5 Recodificación de la variable respuesta

El archivo original define:

$$\text{clase} = \begin{cases} 1, & \text{buen riesgo,} \\ 2, & \text{mal riesgo.} \end{cases}$$

Para el análisis se construye la respuesta binaria:

$$Y_i = \text{mal_credito}_i = \begin{cases} 0, & \text{si } \text{clase}_i = 1, \\ 1, & \text{si } \text{clase}_i = 2. \end{cases}$$

De esta forma, el mal crédito queda definido como el evento positivo. La decisión es coherente con el objetivo del estudio y con la matriz de costos: un falso negativo representa un crédito de mal riesgo clasificado como bueno, es decir, el error al que la fuente asigna el mayor costo.

La recodificación también facilita la interpretación de las métricas. El *recall* de la clase positiva representa directamente la proporción de malos créditos detectados correctamente por el modelo.

Además, se crea `clase_lbl` como una variable categórica ordenada con dos etiquetas:

Buen riesgo y *Mal riesgo*.

Esta variable se utiliza únicamente para mejorar la lectura de tablas y figuras; los cálculos se realizan con `mal_credito`.

La recodificación produce 700 observaciones de buen riesgo y 300 de mal riesgo, equivalentes al 70 % y 30 % del conjunto, respectivamente. Esta distribución será considerada posteriormente al separar los datos y evaluar las métricas del clasificador.

4.6 Tratamiento de categorías informativas

Los códigos A65 y A124 requieren una consideración especial. El primero representa “nivel de ahorros desconocido o sin cuenta”, mientras que el segundo representa “propiedad desconocida o inexistente”. Ambos son códigos definidos por la fuente y no valores faltantes generados durante la carga.

Por tanto, se mantienen como categorías válidas. Reemplazarlos por valores nulos eliminaría una señal potencialmente relevante del proceso de evaluación crediticia. Sin embargo, su interpretación es limitada, porque cada categoría combina dos situaciones diferentes. Por ejemplo, no es posible distinguir entre la ausencia de una cuenta de ahorros y la falta de información sobre ella.

De manera similar, `tasa_cuota` y `anios_residencia` se conservan como escalas ordinales codificadas entre 1 y 4. Estos números representan niveles ordenados, no porcentajes exactos ni años observados directamente. Cuando se utilicen como predictores lineales, esa simplificación deberá considerarse al interpretar sus coeficientes.

4.7 Transformación del monto

El análisis exploratorio muestra que el monto presenta una distribución marcadamente asimétrica hacia la derecha. Después de comprobar que todos sus valores son positivos, se construye:

$$\log_monto_i = \log(monto_i).$$

La transformación logarítmica reduce la influencia relativa de los montos más altos, comprime la escala y permite representar relaciones multiplicativas de una forma más cercana a la linealidad. No sustituye al monto original: ambas variables se conservan y se utilizan según el objetivo de cada análisis.

La pertinencia de esta transformación se evalúa posteriormente mediante el histograma, el gráfico Q-Q y el ajuste por máxima verosimilitud de distribuciones lognormal y gamma.

4.8 Separación entre preprocesamiento y modelamiento

Las operaciones descritas hasta este punto se realizan sobre el conjunto completo porque corresponden a validaciones estructurales, recodificaciones determinísticas y creación de etiquetas.

La separación entre entrenamiento y prueba no forma parte de esta etapa. Se introduce posteriormente, antes del ajuste de la regresión logística, mediante una partición estratificada de 70 % para entrenamiento y 30 % para prueba. La estratificación conserva la proporción de mal crédito en ambos subconjuntos.

Las variables categóricas tampoco se reemplazan globalmente por códigos numéricos arbitrarios. En los modelos de `statsmodels` se incorporan mediante términos categóricos explícitos, dejando una categoría de referencia. De esta manera, la representación utilizada por cada modelo queda vinculada a su especificación y puede interpretarse de forma transparente.

4.9 Resultado del preprocesamiento

El resultado es una base con las 1000 observaciones originales, sin imputaciones ni exclusiones, acompañada por etiquetas legibles y tres variables derivadas principales:

- `mal_credito`, respuesta binaria;
- `clase_lbl`, etiqueta de presentación;
- `log_monto`, transformación logarítmica del monto.

Este conjunto constituye la entrada común para el análisis exploratorio, la inferencia frecuentista, los modelos de regresión y el análisis bayesiano desarrollados en las secciones siguientes.

5 Análisis exploratorio

El análisis exploratorio se realizó sobre las 1000 observaciones del dataset antes de ajustar modelos predictivos. Su finalidad fue reconocer la estructura de la cartera, identificar distribuciones asimétricas, examinar posibles diferencias entre buenos y malos créditos y formular hipótesis que posteriormente pudieran evaluarse mediante inferencia estadística y regresión.

En esta etapa, los resultados se interpretan como asociaciones marginales. Una diferencia observada entre grupos no implica que la variable mantenga el mismo efecto cuando se consideran simultáneamente otras características del solicitante y de la operación. Tampoco permite establecer relaciones causales.

Las visualizaciones que respaldan esta lectura se presentan en la Sección 7. La estadística descriptiva completa, incluidos los estadísticos de posición, dispersión, asimetría y curtosis, se desarrolla en la Sección 6.

5.1 Distribución de la variable respuesta

La muestra contiene 700 operaciones clasificadas como buen riesgo y 300 como mal riesgo. En términos relativos, la tasa observada de mal crédito es:

$$\hat{p} = \frac{300}{1000} = 0.300.$$

Por tanto, la clase mayoritaria representa el 70 % de la muestra y la clase de interés el 30 %. Se trata de un desbalance moderado, pero suficiente para que la exactitud global pueda ofrecer una impresión incompleta del desempeño predictivo.

Por ejemplo, una regla trivial que clasificara todos los registros como buen riesgo alcanzaría una exactitud del 70 %, aunque no identificaría ningún caso de mal crédito. Esta observación justifica que la evaluación posterior incluya *recall*, precisión, matrices de confusión, ROC–AUC y costos de clasificación, en lugar de utilizar únicamente el *accuracy*.

Hallazgo principal. La clase positiva no es mayoritaria. En consecuencia, el desempeño del modelo debe evaluarse por su capacidad para identificar malos créditos y por el costo de los errores, no solo por el porcentaje total de clasificaciones correctas.

5.2 Propósito del préstamo

La tasa global de mal crédito no se distribuye de manera uniforme entre los propósitos declarados. La categoría Educación presenta la mayor tasa entre los grupos con tamaño moderado, con 22 malos créditos de 50 observaciones, equivalente al 44.0 %. Le siguen Auto nuevo, con 38.0 %, y Negocio, con 35.1 %.

En el extremo inferior aparecen Radio/TV, con una tasa de 22.1 %, Auto usado, con 16.5 %, y Reentrenamiento, con 11.1 %. La diferencia entre Educación y la tasa global es de 14.0 puntos porcentuales, mientras que Auto usado se sitúa 13.5 puntos porcentuales por debajo del promedio de la cartera.

Sin embargo, la comparación requiere considerar el tamaño de cada categoría. Otros, Reparaciones, Electrodomésticos y Reentrenamiento contienen menos de treinta observaciones. En estos grupos, una variación de pocos casos produce cambios importantes en la tasa calculada.

La Tabla 8 presenta los resultados exploratorios principales.

Cuadro 8: Tasa observada de mal crédito según el propósito del préstamo.

Propósito	Total	Malos	Tasa de mal crédito	Diferencia frente al global
Educación	50	22	44.0 %	+14.0 pp
Otros	12	5	41.7 %	+11.7 pp
Auto nuevo	234	89	38.0 %	+8.0 pp
Reparaciones	22	8	36.4 %	+6.4 pp
Negocio	97	34	35.1 %	+5.1 pp
Electrodomésticos	12	4	33.3 %	+3.3 pp
Mobiliario/equipos	181	58	32.0 %	+2.0 pp
Radio/TV	280	62	22.1 %	-7.9 pp
Auto usado	103	17	16.5 %	-13.5 pp
Reentrenamiento	9	1	11.1 %	-18.9 pp

Nota. La tasa global de mal crédito es 30.0 %. Las categorías Otros, Reparaciones, Electrodomésticos y Reentrenamiento tienen menos de 30 observaciones; sus tasas deben interpretarse con mayor cautela.

Estas diferencias sugieren una asociación entre el propósito del préstamo y la clasificación de riesgo. No obstante, la evidencia exploratoria no permite concluir todavía que la asociación sea estadísticamente significativa. La prueba correspondiente se presenta en la Sección 9.

5.3 Duración del crédito

La duración muestra uno de los contrastes exploratorios más claros entre las dos clases. En los buenos créditos, la mediana es de 18 meses y la media de 19.21 meses. En los malos créditos, la mediana aumenta a 24 meses y la media a 24.86 meses.

También cambia la dispersión. El rango intercuartílico es de 12 meses entre los buenos créditos y de 24 meses entre los malos. Por tanto, el grupo de mal riesgo no solo presenta contratos más prolongados, sino también una mayor heterogeneidad en sus plazos.

Desde una perspectiva de riesgo, una duración mayor amplía el horizonte durante el cual pueden cambiar los ingresos del solicitante, sus gastos, el entorno económico o su capacidad de pago. Sin embargo, esta lectura es una interpretación financiera plausible y no una relación causal demostrada por los datos.

5.4 Monto del crédito

El monto también presenta valores superiores entre los casos de mal riesgo. La mediana es de 2244 DM para los buenos créditos y de 2574.5 DM para los malos. Las medias son 2985.46 DM y 3938.13 DM, respectivamente.

La diferencia entre medias es mayor que la diferencia entre medianas, debido a la fuerte asimetría de la distribución y a la presencia de operaciones de importe elevado. Además, el rango intercuartílico del monto es de 2259.25 DM para los buenos créditos y de 3789 DM para los malos.

Estas características indican que la comparación no debe descansar únicamente en la media. Por ello, el análisis posterior utiliza la mediana, métodos no paramétricos y la transformación `log_monto`, según el objetivo de cada procedimiento.

Existe, además, un solapamiento considerable entre ambas clases. Hay buenos créditos de monto elevado y malos créditos de monto reducido. En consecuencia, el monto aporta información sobre el perfil de riesgo, pero no permite separar por sí solo las dos clases.

5.5 Edad del solicitante

Los casos clasificados como mal riesgo corresponden, en promedio, a solicitantes algo más jóvenes. La mediana de edad es de 31 años en el grupo de mal riesgo y de 34 años en el grupo de buen riesgo. Las medias respectivas son 33.96 y 36.22 años.

La diferencia es menor que la observada en la duración y existe un amplio solapamiento entre ambas distribuciones. La edad se considera, por tanto, una señal potencialmente relevante, pero insuficiente para sostener una conclusión aislada. Su contribución deberá evaluarse dentro del modelo multivariable.

Además, por tratarse de una característica personal, cualquier uso operacional de la edad requeriría revisar su pertinencia regulatoria, ética y de equidad.

5.6 Carga de la cuota

La variable `tasa_cuota` representa una escala ordinal de carga financiera, no el porcentaje exacto de la cuota sobre el ingreso. El nivel 4, correspondiente a la categoría superior de la escala, concentra el 53.0 % de los malos créditos y el 45.3 % de los buenos.

Esta comparación no significa que la tasa de mal crédito del nivel 4 sea del 53.0 %. El porcentaje está calculado dentro de cada clase y muestra que la categoría superior tiene mayor presencia relativa entre los casos de mal riesgo.

El patrón es compatible con la hipótesis de que una mayor carga de pago puede reducir el margen financiero disponible del solicitante. No obstante, la interpretación debe mantenerse en términos ordinales, porque el dataset no proporciona el porcentaje exacto de ingreso comprometido.

5.7 Relaciones monotónicas entre variables

La matriz de correlaciones de Spearman permite evaluar asociaciones monotónicas entre las variables numéricas, las escalas ordinales y la respuesta binaria.

La relación más alta aparece entre duración y monto:

$$\rho_{\text{duración, monto}} = 0.62.$$

Esto indica que los créditos de mayor importe tienden a contratarse por plazos más extensos. La relación es suficientemente relevante para justificar una revisión posterior de multicolinealidad, aunque no implica que ambos predictores sean equivalentes.

En relación con la respuesta:

$$\rho_{\text{duración, mal crédito}} = 0.21,$$

$$\rho_{\text{monto, mal crédito}} = 0.09,$$

$$\rho_{\text{edad, mal crédito}} = -0.11.$$

La duración presenta la asociación monotónica marginal más clara con el mal crédito. El monto tiene una asociación positiva mucho menor, mientras que la edad muestra una asociación negativa débil. Las demás variables numéricas y ordinales presentan coeficientes próximos a cero.

Estos resultados no deben utilizarse para descartar automáticamente predictores. Una correlación marginal reducida puede coexistir con una asociación condicional relevante cuando se controlan otras variables, especialmente en presencia de categorías, interacciones o relaciones no lineales.

5.8 Síntesis exploratoria

La Tabla 9 resume los patrones que orientan las etapas siguientes.

Cuadro 9: Síntesis de los principales patrones exploratorios.

Dimensión	Evidencia exploratoria	Implicancia analítica
Clase de riesgo	70 % buenos y 30 % malos.	No evaluar el modelo únicamente mediante exactitud.
Propósito	Tasas entre 11.1 % y 44.0 %, con tamaños de grupo heterogéneos.	Aplicar prueba de independencia y considerar la estabilidad de las categorías pequeñas.
Duración	Mediana de 18 meses en buenos y 24 meses en malos.	Comparar grupos y evaluar su asociación condicional.
Monto	Valores mayores y más dispersos en los malos créditos.	Utilizar medidas robustas, escala logarítmica y contraste no paramétrico.
Edad	Mediana de 34 años en buenos y 31 en malos.	Evaluar si la asociación persiste dentro del modelo multivariable.
Nivel de cuota	Mayor presencia del nivel 4 entre los malos créditos.	Interpretar como escala ordinal y no como porcentaje exacto.
Duración– monto	Correlación de Spearman de 0.62.	Revisar redundancia y multicolinealidad.

En conjunto, el EDA señala que la duración, el monto, la edad, la carga de la cuota y el propósito contienen información potencialmente útil para caracterizar el riesgo crediticio. Sin embargo, ninguna de estas variables separa de forma completa las clases y todas las comparaciones siguen siendo marginales.

Las diferencias observadas se someterán a contrastes frecuentistas y a modelos multivariados. Esta transición es necesaria para determinar qué patrones se sostienen después de cuantificar la incertidumbre y controlar simultáneamente por otras características.

6 Estadística descriptiva

La estadística descriptiva complementa el análisis exploratorio mediante medidas de posición, dispersión y forma. Mientras la Sección 5 identificó patrones generales de la cartera, esta sección cuantifica esos patrones y examina con mayor detalle la distribución del monto del crédito.

Para las variables numéricas se calcularon la media, la desviación estándar muestral, la mediana, los cuartiles, el rango intercuartílico, los valores mínimo y máximo, la asimetría y la curtosis en exceso. La media y la desviación estándar permiten resumir el centro y la dispersión cuando la distribución no presenta una asimetría extrema; la mediana y el rango intercuartílico ofrecen una descripción más robusta ante colas largas y observaciones alejadas del centro.

6.1 Resumen de las variables numéricas

La Tabla 10 presenta los principales estadísticos de las cinco variables numéricas originales.

Cuadro 10: Estadística descriptiva de las variables numéricas.

Variable	Media	Desv. est.	Mediana	Q1	Q3	RIC	Mín.–Máx.	Asimetría
Duración	20,90	12,06	18	12	24	12	4–72	1,09
Monto	3.271,26	2.822,74	2.319,50	1.365,50	3.972,25	2.606,75	250–18.424	1,95
Edad	35,55	11,38	33	27	42	15	19–75	1,02
Créditos en el banco	1,41	0,58	1	1	2	1	1–4	1,27
Dependientes	1,16	0,36	1	1	1	0	1–2	1,91

Nota. Q1 y Q3 representan los cuartiles primero y tercero. RIC corresponde al rango intercuartílico. La duración se expresa en meses, el monto en marcos alemanes (DM) y la edad en años. Todas las variables tienen $n = 1000$ observaciones y no presentan valores faltantes.

La duración media es de 20,90 meses, mientras que su mediana es de 18 meses. La diferencia entre ambas medidas y una asimetría de 1,09 muestran que los plazos se concentran en valores relativamente bajos, pero incluyen una cola formada por créditos de mayor duración.

La edad presenta un comportamiento similar. Su media es de 35,55 años y su mediana de 33 años, con una asimetría positiva de 1,02. Aunque la mayor parte de los solicitantes se concentra entre 27 y 42 años, la muestra incluye personas de hasta 75 años.

Las variables `n_creditos_banco` y `n_dependientes` tienen una escala reducida. En particular, el rango intercuartílico de `n_dependientes` es cero porque los cuartiles primero, segundo y tercero toman el valor uno. Esto no significa ausencia total de variabilidad, sino una fuerte concentración en la categoría más frecuente.

6.2 Forma de la distribución del monto

El monto es la variable con mayor heterogeneidad. La media es de 3.271,26 DM, mientras que la mediana es de 2.319,50 DM. La diferencia de casi mil marcos entre ambas medidas evidencia la influencia de los créditos situados en la cola derecha.

La variable presenta:

$$\text{asimetra} = 1,95, \quad \text{curtosis en exceso} = 4,29.$$

La asimetría positiva indica que la distribución se extiende hacia los montos elevados. La curtosis en exceso sugiere una concentración central y unas colas más pronunciadas que las

de una distribución normal. El monto máximo, 18.424 DM, es casi ocho veces la mediana de la muestra.

Estos resultados justifican tres decisiones posteriores:

1. complementar la media con la mediana y el rango intercuartílico;
2. utilizar pruebas robustas o no paramétricas al comparar grupos;
3. considerar el logaritmo del monto cuando se requiera reducir la asimetría o modelar relaciones multiplicativas.

La transformación logarítmica no elimina la información de los créditos de mayor monto. Su función es comprimir la escala y reducir la influencia relativa de las observaciones extremas.

6.3 Descriptivos por clase de riesgo

La Tabla 11 compara duración, monto y edad entre los grupos de buen y mal riesgo.

Cuadro 11: Estadística descriptiva de las variables principales según la clase de riesgo.

Variable	Clase	<i>n</i>	Media	Desv. est.	Q1	Mediana	Q3	RIC
Duración	Buen riesgo	700	19,21	11,08	12	18	24	12
Duración	Mal riesgo	300	24,86	13,28	12	24	36	24
Monto	Buen riesgo	700	2.985,46	2.401,47	1.375,50	2.244	3.634,75	2.259,25
Monto	Mal riesgo	300	3.938,13	3.535,82	1.352,50	2.574,50	5.141,50	3.789
Edad	Buen riesgo	700	36,22	11,38	27	34	42,25	15,25
Edad	Mal riesgo	300	33,96	11,22	25	31	40	15

Nota. Los resultados son descriptivos y no constituyen por sí solos evidencia de diferencias poblacionales. Los contrastes formales se presentan en la Sección 9.

La diferencia más visible corresponde a la duración. Los malos créditos tienen una mediana de 24 meses, frente a 18 meses en los buenos. Además, su rango intercuartílico es el doble, lo que muestra una mayor variabilidad de los plazos dentro del grupo de mal riesgo.

El monto medio aumenta de 2.985,46 DM a 3.938,13 DM y la mediana de 2.244 DM a 2.574,50 DM. La diferencia entre medias es mayor que la diferencia entre medianas, lo que confirma que parte del contraste está influido por operaciones elevadas en la cola derecha.

La edad muestra una diferencia más moderada. Los solicitantes de mal riesgo tienen una mediana de 31 años, frente a 34 años en los buenos créditos. El solapamiento entre grupos continúa siendo amplio, por lo que ninguna de estas variables debe interpretarse de manera aislada como una regla de clasificación.

6.4 Ajuste paramétrico del monto mediante máxima verosimilitud

Debido a que el monto es positivo y presenta una cola derecha pronunciada, se compararon dos familias continuas con soporte positivo: Lognormal y Gamma. Ambas

distribuciones se ajustaron mediante máxima verosimilitud utilizando las funciones `scipy.stats.lognorm.fit()` y `scipy.stats.gamma.fit()`.

En los dos modelos se fijó el parámetro de localización en cero:

$$\text{loc} = 0.$$

Esta restricción mantiene el soporte de las distribuciones a partir de cero y deja dos parámetros libres en cada modelo.

Para la distribución Lognormal:

$$X \sim \text{Lognormal}(\mu, \sigma),$$

de modo que:

$$\log(X) \sim \mathcal{N}(\mu, \sigma^2).$$

Con $\text{loc} = 0$, los estimadores cerrados son:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \log(x_i),$$

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n [\log(x_i) - \hat{\mu}]^2}.$$

La estimación obtenida fue:

$$\hat{\mu} = 7,788.691, \quad \hat{\sigma} = 0,776.086.$$

Los valores coinciden, hasta la precisión numérica, con los parámetros devueltos por SciPy. Esta comprobación sirve como verificación independiente de la implementación.

Para la distribución Gamma se utilizó la parametrización forma–escala:

$$X \sim \text{Gamma}(k, \theta),$$

con estimaciones:

$$\hat{k} = 1,792.1, \quad \hat{\theta} = 1.825,396.2.$$

6.5 Comparación mediante log-verosimilitud y AIC

Los modelos se compararon mediante la log-verosimilitud maximizada y el criterio de información de Akaike:

$$\text{AIC} = 2k - 2\ell(\hat{\theta}),$$

donde k es el número de parámetros libres y $\ell(\hat{\theta})$ la log-verosimilitud evaluada en los estimadores de máxima verosimilitud. En ambos modelos se utilizó $k = 2$, porque el parámetro de localización se mantuvo fijo.

Cuadro 12: Comparación de los ajustes Lognormal y Gamma para el monto del crédito.

Distribución	Parámetro 1	Valor	Parámetro 2	Valor	Log-verosimilitud	AIC
Lognormal	μ	7,788.7	σ	0,776.1	-8.954,137.5	17.912,275.1
Gamma	k	1,792.1	θ	1.825,396.2	-9.007,215.2	18.018,430.5

La distribución Lognormal presenta una log-verosimilitud mayor y un AIC menor. La diferencia es:

$$\Delta \text{AIC} = 18.018,430.5 - 17.912,275.1 = 106,155.4.$$

Dentro de las dos familias evaluadas, esta diferencia favorece de manera clara al modelo Lognormal. El resultado no demuestra que la Lognormal sea la distribución verdadera del monto ni que proporcione un ajuste perfecto. El AIC permite realizar una comparación relativa entre los modelos candidatos, pero no constituye una prueba absoluta de bondad de ajuste.

La evidencia gráfica complementaria muestra que los cuantiles de $\log(\text{monto})$ siguen aproximadamente una línea recta en la parte central, aunque presentan desviaciones en las colas. En consecuencia, la Lognormal ofrece una aproximación útil para describir la forma general de la distribución, pero conserva limitaciones en los valores extremos.

Hallazgo principal. Entre las distribuciones comparadas, la Lognormal describe mejor el monto del crédito. Este resultado respalda el uso de `log_monto` para reducir la asimetría, pero no sustituye los diagnósticos específicos de los modelos posteriores.

6.6 Implicancias para los análisis posteriores

La transformación logarítmica se empleará cuando resulte conveniente para reducir la escala de los montos elevados y representar relaciones proporcionales. En el modelo OLS, su utilidad deberá evaluarse mediante el comportamiento de los residuos, la homocedasticidad y la validación cruzada.

En la regresión logística, la transformación no se utiliza porque los predictores deban seguir una distribución normal. El modelo logístico no exige normalidad marginal de las variables explicativas. Su incorporación responde a una decisión sobre la forma funcional de la relación entre el monto y el logit de la probabilidad de mal crédito.

Finalmente, la asimetría observada justifica que la comparación del monto entre buenos y malos créditos no se limite a una prueba sobre medias. En la Sección 9 se complementará la prueba de Welch con un contraste de Mann–Whitney basado en rangos.

7 Visualizaciones

Las visualizaciones se diseñaron como parte del flujo reproducible del notebook y se exportaron a la carpeta **resultados/figuras**. Cada gráfico responde a una pregunta analítica concreta: describir la composición de la cartera, comparar grupos, examinar asociaciones, evaluar supuestos o comunicar el desempeño de los modelos.

El informe contiene once figuras generadas directamente a partir de los datos y resultados computacionales. En esta sección se presentan las cinco visualizaciones descriptivas y exploratorias. Las seis figuras restantes se incorporan posteriormente junto con el análisis al que pertenecen: diagnóstico de regresión, interpretación del modelo logístico, selección del umbral y análisis bayesiano.

Esta distribución evita convertir la sección en una galería desconectada del argumento estadístico y mantiene cada figura cerca de la evidencia que permite interpretar.

7.1 Criterios de presentación

Las figuras siguen cuatro criterios comunes:

1. presentan títulos, ejes, unidades y categorías legibles;
2. utilizan una paleta consistente para distinguir el buen y el mal riesgo;
3. evitan efectos decorativos que no aportan información, como perspectivas tridimensionales o escalas innecesarias;
4. se exportan desde el notebook en formato PNG y alta resolución, de modo que el resultado pueda reproducirse sin editar manualmente el gráfico.

Las visualizaciones deben interpretarse junto con las tablas y pruebas correspondientes. Un contraste visual puede sugerir una diferencia, pero no sustituye la cuantificación de incertidumbre ni una prueba de hipótesis.

7.2 Composición de la cartera

La Figura 1 muestra la distribución de la variable respuesta.




Figura 1: Distribución de los registros según la clase de riesgo crediticio.

La figura permite reconocer de inmediato que el buen riesgo es la clase mayoritaria. La muestra contiene 700 buenos créditos y 300 malos, equivalentes al 70 % y 30 %, respectivamente.

El gráfico no muestra un desbalance extremo, pero sí una diferencia suficiente para que una clasificación basada únicamente en la clase mayoritaria alcance una exactitud aparentemente elevada. Por esta razón, las métricas posteriores se orientan especialmente a la detección de los casos de mal crédito.

7.3 Tasa de mal crédito por propósito

La Figura 2 compara la proporción observada de mal crédito entre los propósitos declarados del préstamo.




Figura 2: Tasa observada de mal crédito según el propósito del préstamo. La línea de referencia representa la tasa global de la cartera.

La comparación revela heterogeneidad entre categorías. Educación, Auto nuevo y Negocio se sitúan por encima de la tasa global, mientras que Radio/TV, Auto usado y Reentrenamiento presentan tasas menores.

La altura de una barra debe interpretarse junto con el número de observaciones que la origina. Las categorías pequeñas pueden presentar porcentajes extremos debido a unos pocos registros. Por ello, el gráfico se utiliza como evidencia exploratoria y se complementa posteriormente con una prueba chi-cuadrado y una medida de tamaño de efecto.

7.4 Duración y monto según la clase

La Figura 3 presenta la distribución de las dos variables contractuales principales según la clasificación de riesgo.




Figura 3: Distribución de la duración y el monto del crédito según la clase de riesgo.

El panel de duración muestra un desplazamiento más claro entre las clases. Los casos de mal riesgo presentan una mediana superior y una mayor dispersión de los plazos. En el monto también se observan valores centrales más altos entre los malos créditos, aunque el solapamiento entre ambos grupos es considerable.

Los valores alejados de las cajas no se eliminaron. Representan operaciones válidas y aportan información sobre la cola de las distribuciones. Su presencia explica por qué las comparaciones se complementan con medidas robustas y pruebas basadas en rangos.

7.5 Asociaciones monotónicas

La Figura 4 resume las correlaciones de Spearman entre las variables numéricas, las escalas ordinales y la respuesta binaria.




Figura 4: Matriz de correlaciones de Spearman entre las variables cuantitativas y ordinales del análisis.

La asociación más visible se presenta entre duración y monto. Los créditos de mayor importe tienden a distribuirse en plazos más largos. Esta relación no implica redundancia completa, pero justifica revisar la multicolinealidad antes de interpretar los coeficientes de regresión.

Respecto de la variable respuesta, la duración presenta la asociación monotónica marginal más alta. Las relaciones del monto y la edad con el mal crédito son menores. Estas correlaciones no incluyen la información de las variables categóricas ni controlan simultáneamente los demás predictores, por lo que no reemplazan el análisis multivariable.

7.6 Ajuste paramétrico del monto

La Figura 5 compara visualmente los ajustes Lognormal y Gamma estimados mediante máxima verosimilitud.




Figura 5: Ajuste paramétrico del monto del crédito. El panel izquierdo compara las densidades Lognormal y Gamma con el histograma observado; el panel derecho evalúa la normalidad aproximada del logaritmo del monto mediante un gráfico Q-Q.

La distribución Lognormal reproduce mejor la concentración central y la cola derecha del monto que la distribución Gamma. Esta lectura visual es consistente con la comparación mediante AIC desarrollada en la Sección 6.

El gráfico Q-Q muestra un comportamiento aproximadamente lineal en la zona central de $\log(\text{monto})$, acompañado de desviaciones en las colas. En consecuencia, la transformación logarítmica mejora la representación general de la variable, pero no elimina completamente la influencia de los montos extremos.

8 Análisis de incertidumbre frecuentista

La proporción observada de malos créditos describe la composición de la muestra, pero no expresa por sí sola la precisión de la estimación. Para cuantificar esta incertidumbre se construyeron dos intervalos de confianza del 95 % para la tasa de mal crédito: un intervalo analítico de Wilson y un intervalo bootstrap percentil.

Como análisis complementario, se estimó también un intervalo basado en la distribución t de Student para la duración media del crédito. Esta segunda estimación permite distinguir la incertidumbre asociada con una proporción binomial de la incertidumbre correspondiente a la media de una variable cuantitativa.

Los resultados completos se generan en el notebook y se exportan en:

resultados/tablas/tabla_intervalos_confianza.csv

8.1 Proporción observada de malos créditos

Sea Y_i la variable binaria que identifica un mal crédito:

$$Y_i = \begin{cases} 1, & \text{si la observación corresponde a mal riesgo,} \\ 0, & \text{si corresponde a buen riesgo.} \end{cases}$$

Bajo un modelo binomial:

$$X = \sum_{i=1}^n Y_i \sim \text{Binomial}(n, p),$$

donde p representa la proporción poblacional desconocida de malos créditos.

En la muestra analizada:

$$n = 1000, \quad x = 300,$$

por lo que la estimación puntual es:

$$\hat{p} = \frac{x}{n} = \frac{300}{1000} = 0.300.$$

La tasa observada de mal crédito es, por tanto, del 30.0 %.

8.2 Intervalo analítico de Wilson

Para estimar p se utilizó el intervalo de Wilson. A diferencia del intervalo de Wald, este procedimiento incorpora una corrección tanto en el centro como en el margen del intervalo y suele presentar una cobertura más estable para proporciones binomiales.

Para un nivel de confianza $1 - \alpha$, el intervalo se define como:

$$\text{IC}_{\text{Wilson}} = \frac{\hat{p} + \frac{z_{1-\alpha/2}^2}{2n} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z_{1-\alpha/2}^2}{4n^2}}}{1 + \frac{z_{1-\alpha/2}^2}{n}}.$$

Para un nivel de confianza del 95 %:

$$\alpha = 0.05, \quad z_{1-\alpha/2} \approx 1.96.$$

El intervalo obtenido fue:

$$\text{IC}_{95\%, \text{Wilson}} = [0.2724, 0.3291].$$

En términos porcentuales:

$$27.24\% \leq p \leq 32.91\%.$$

La amplitud total del intervalo es de aproximadamente 5.67 puntos porcentuales. De forma equivalente, el margen alrededor de la estimación central es cercano a 2.84 puntos porcentuales.

El cálculo se implementó explícitamente en el notebook y se verificó mediante la función `proportion_confint()` de `statsmodels`. Ambas implementaciones produjeron los mismos límites dentro de la tolerancia numérica utilizada.

8.3 Intervalo bootstrap percentil

Como método de remuestreo se utilizó un bootstrap no paramétrico. El procedimiento genera $B = 10\,000$ muestras con reemplazo, cada una de tamaño $n = 1000$, a partir de los registros observados.

Para cada réplica b se calculó:

$$\widehat{p}^{*(b)} = \frac{1}{n} \sum_{i=1}^n Y_i^{*(b)}.$$

La colección:

$$\widehat{p}^{*(1)}, \widehat{p}^{*(2)}, \dots, \widehat{p}^{*(B)}$$

aproxima la distribución muestral de la proporción. El intervalo percentil se construye mediante los cuantiles 0.025 y 0.975:

$$\text{IC}_{\text{bootstrap}} = [Q_{0.025}(\widehat{p}^*), Q_{0.975}(\widehat{p}^*)].$$

Con la semilla reproducible `SEED = 2026`, el resultado fue:

$$\text{IC}_{95\%, \text{bootstrap}} = [0.2720, 0.3290].$$

En términos porcentuales:

$$27.20\% \leq p \leq 32.90\%.$$

El error estándar estimado a partir de las réplicas bootstrap fue:

$$\widehat{\text{SE}}_{\text{bootstrap}} = 0.0145.$$

La amplitud total del intervalo bootstrap es de 5.70 puntos porcentuales, prácticamente igual a la obtenida mediante Wilson.

8.4 Comparación de los intervalos para la proporción

La Tabla 14 resume los resultados.

Cuadro 13: Intervalos de confianza del 95 % para la proporción de malos créditos.

Método	Estimación	Límite inferior	Límite superior	Amplitud
Wilson	0,300.0	0,272.4	0,329.1	0,056.7
Bootstrap percentil	0,300.0	0,272.0	0,329.0	0,057.0

Los dos procedimientos producen resultados casi idénticos. La diferencia entre sus límites inferiores es de solo 0.0004, mientras que la diferencia entre los límites superiores es de 0.0001.

Esta concordancia se explica por el tamaño de la muestra y porque la proporción observada no se encuentra cerca de los extremos cero o uno. En estas condiciones, la distribución muestral de $\hat{p}$ es aproximadamente simétrica y el remuestreo reproduce de manera cercana la incertidumbre capturada por el intervalo analítico.

Hallazgo principal. La tasa de mal crédito se estima en 30.0 %, con límites cercanos a 27.2 % y 32.9 %. La concordancia entre Wilson y bootstrap indica que la estimación es estable frente a los dos procedimientos de construcción considerados.

8.5 Intervalo para la duración media

También se construyó un intervalo de confianza para la media poblacional de la duración del crédito. Sea:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

la duración media muestral y s la desviación estándar muestral. El intervalo basado en la distribución t de Student es:

$$\bar{x} \pm t_{1-\alpha/2, n-1} \frac{s}{\sqrt{n}}.$$

La estimación observada fue:

$$\bar{x} = 20.903 \text{ meses.}$$

El intervalo del 95 % fue:

$$IC_{95\%, t} = [20.1547, 21.6513] \text{ meses.}$$

La amplitud total es de aproximadamente 1.50 meses. Este resultado indica que la media de la duración se estima con una precisión relativamente alta dentro de la población representada por la muestra.

Debe distinguirse esta incertidumbre de la variabilidad entre créditos. El intervalo estrecho corresponde a la precisión de la media estimada; no significa que las duraciones individuales se encuentren próximas a 20.9 meses. Como se observó en la estadística descriptiva, los contratos varían entre 4 y 72 meses.

Cuadro 14: Resumen de los intervalos de confianza construidos.

Parámetro	Método	Estimación	IC del 95 %	Unidad
Proporción de mal crédito	Wilson	0,300	[0.2724, 0.3291]	Proporción
Proporción de mal crédito	Bootstrap percentil, $B = 10.000$	0,300	[0.2720, 0.3290]	Proporción
Media de la duración	t de Student	20,903	[20.1547, 21.6513]	Meses

8.6 Interpretación frecuentista

Los intervalos no deben interpretarse como una probabilidad posterior sobre un parámetro fijo. Una vez calculado el intervalo, el parámetro poblacional se encuentra dentro o fuera de sus límites; no se asigna una probabilidad del 95 % a ese evento dentro del enfoque frecuentista.

La interpretación se refiere al procedimiento: si se extrajeran muchas muestras comparables y se construyera un intervalo mediante el mismo método en cada una, aproximadamente el 95 % de esos intervalos contendría el verdadero parámetro poblacional.

Esta interpretación se diferencia del intervalo creíble bayesiano que se presentará en la Sección 11. En el enfoque bayesiano, la incertidumbre se expresa directamente mediante una distribución posterior para p .

8.7 Supuestos y alcance

El intervalo de Wilson se apoya en un modelo binomial y supone que las observaciones representan ensayos comparables e independientes. El bootstrap utilizado también remuestrea registros individuales, por lo que mantiene implícitamente una estructura de independencia entre las filas.

Además, ambos métodos cuantifican la incertidumbre muestral condicionada a la composición del dataset. No corrigen posibles sesgos derivados del proceso de selección original, la antigüedad de los datos ni la falta de representatividad respecto de una cartera actual.

Por ello, el intervalo:

$$[27.2 \%, 32.9 \%]$$

describe la precisión de la tasa dentro de una población comparable con la muestra analizada. No debe interpretarse como una estimación directa de la tasa de incumplimiento de

una entidad financiera peruana ni de una cartera contemporánea sin una validación externa adicional.

La cercanía entre Wilson y bootstrap aporta evidencia de estabilidad numérica, pero no elimina las limitaciones de validez externa del dataset.

9 Inferencia estadística frecuentista

El análisis exploratorio mostró diferencias en la tasa de mal crédito según el propósito del préstamo y contrastes en la duración y el monto entre las clases de riesgo. En esta sección se evalúa si esas diferencias pueden atribuirse únicamente a la variabilidad muestral o si existe evidencia estadística de asociación.

Se realizaron tres contrastes previamente definidos por las preguntas de investigación:

1. prueba chi-cuadrado de independencia entre propósito y clase de riesgo;
2. prueba t de Welch para comparar la duración media;
3. prueba U de Mann–Whitney para comparar la distribución del monto.

En todos los contrastes se utilizó un nivel de significancia de:

$$\alpha = 0.05.$$

Los valores p se acompañan con medidas de tamaño de efecto. Esta distinción es importante porque una diferencia puede ser estadísticamente significativa sin tener una magnitud relevante desde el punto de vista crediticio u operativo.

9.1 Asociación entre propósito y clase de riesgo

La primera pregunta inferencial es:

¿La proporción de malos créditos difiere según el propósito del préstamo?

Las variables `proposito_lbl` y `mal_credito` son categóricas. Por ello, se utilizó una prueba chi-cuadrado de independencia.

Las hipótesis fueron:

H_0 : el propósito y la clase de riesgo son independientes,

H_1 : el propósito y la clase de riesgo están asociados.

El estadístico se define como:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

donde O_{ij} representa la frecuencia observada y E_{ij} la frecuencia esperada bajo independencia.

Las frecuencias esperadas se calculan mediante:

$$E_{ij} = \frac{n_{i.} \cdot n_{.j}}{n}.$$

La tabla observada se presenta en la Tabla 16.

Cuadro 15: Frecuencias observadas de la clase de riesgo según el propósito del préstamo.

Propósito	Buen riesgo	Mal riesgo	Total
Auto nuevo	145	89	234
Auto usado	86	17	103
Educación	28	22	50
Electrodomésticos	8	4	12
Mobiliario/equipos	123	58	181
Negocio	63	34	97
Otros	7	5	12
Radio/TV	218	62	280
Reentrenamiento	8	1	9
Reparaciones	14	8	22
Total	700	300	1000

El contraste produjo:

$$\chi^2(9) = 33.356, \quad p = 0.00012.$$

Como:

$$p < 0.05,$$

se rechaza la hipótesis nula de independencia. Existe evidencia estadística de una asociación entre el propósito declarado del préstamo y la clasificación crediticia.

9.1.1 Verificación de las frecuencias esperadas

La validez de la aproximación chi-cuadrado depende de que las frecuencias esperadas no sean excesivamente pequeñas. En la tabla analizada:

- ninguna celda tuvo una frecuencia esperada menor que 1;
- tres de las veinte celdas tuvieron una frecuencia esperada menor que 5;
- esas tres celdas representan el 15 % del total.

Por tanto, se cumple el criterio habitual según el cual no debe haber frecuencias esperadas menores que uno y no más del 20 % de las celdas deben situarse por debajo de cinco.

La aproximación chi-cuadrado resulta razonable, aunque las categorías con pocos registros deben interpretarse con cautela.

9.2 Magnitud de la asociación: V de Cramér

El rechazo de H_0 indica que existe una asociación, pero no informa sobre su intensidad. Para cuantificarla se utilizó la V de Cramér:

$$V = \sqrt{\frac{\chi^2}{n \min(r-1, c-1)}}.$$

El resultado fue:

$$V = 0.183.$$

Este valor corresponde a una asociación de magnitud pequeña. El propósito aporta información sobre la clasificación de riesgo, pero su capacidad explicativa individual es limitada.

La significancia estadística debe interpretarse considerando que el dataset contiene 1000 observaciones. Con muestras relativamente grandes, asociaciones modestas pueden producir valores p pequeños.

9.3 Categorías que contribuyen a la asociación

Para identificar las categorías con mayor contribución se examinaron los residuos estandarizados de Pearson:

$$R_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}.$$

Un residuo positivo en la columna de mal crédito indica que se observaron más casos de riesgo que los esperados bajo independencia; un residuo negativo indica menos casos de los esperados.

La Tabla 17 presenta los residuos de la clase de mal riesgo.

Cuadro 16: Residuos estandarizados para la clase de mal riesgo según el propósito.

Propósito	Malos observados	Malos esperados	Residuo estandarizado
Auto nuevo	89	70,2	2,244
Educación	22	15,0	1,807
Negocio	34	29,1	0,908
Otros	5	3,6	0,738
Reparaciones	8	6,6	0,545
Mobiliario/equipos	58	54,3	0,502
Electrodomésticos	4	3,6	0,211
Reentrenamiento	1	2,7	-1,035
Radio/TV	62	84,0	-2,400
Auto usado	17	30,9	-2,501

Las mayores desviaciones corresponden a:

- Auto nuevo, con más malos créditos que los esperados;
- Radio/TV, con menos malos créditos que los esperados;
- Auto usado, también con menos malos créditos que los esperados.

Educación presenta una tasa observada elevada, pero su residuo no alcanza la misma magnitud que los anteriores debido al menor tamaño de la categoría. Esto muestra por qué no basta comparar porcentajes: la incertidumbre depende también del número de observaciones.

Los residuos son diagnósticos descriptivos posteriores a una prueba global. No constituyen por sí solos diez pruebas independientes ni deben interpretarse como evidencia causal de que el propósito produzca el riesgo.

Hallazgo principal. El propósito del préstamo está asociado con la clase crediticia, pero la magnitud global es pequeña. El propósito aporta una señal de riesgo, no una regla suficiente para clasificar individualmente a un solicitante.

9.4 Comparación de la duración

La segunda pregunta evaluada fue si la duración del crédito difiere entre buenos y malos riesgos.

Las hipótesis fueron:

$$H_0 : \mu_{\text{mal}} = \mu_{\text{buen}},$$

$$H_1 : \mu_{\text{mal}} \neq \mu_{\text{buen}}.$$

Se utilizó la prueba t de Welch porque no exige igualdad de varianzas entre los grupos. El estadístico puede expresarse como:

$$t = \frac{\bar{x}_{\text{mal}} - \bar{x}_{\text{buen}}}{\sqrt{\frac{s_{\text{mal}}^2}{n_{\text{mal}}} + \frac{s_{\text{buen}}^2}{n_{\text{buen}}}}}.$$

Los resultados descriptivos fueron:

$$\bar{x}_{\text{buen}} = 19.21 \text{ meses},$$

$$\bar{x}_{\text{mal}} = 24.86 \text{ meses}.$$

La diferencia observada fue:

$$24.86 - 19.21 = 5.65 \text{ meses}.$$

El contraste produjo:

$$t = 6.470, \quad p < 0.001.$$

Se rechaza la hipótesis de igualdad de medias. Los créditos clasificados como mal riesgo presentan una duración media significativamente mayor que los clasificados como buen riesgo.

9.5 Tamaño del efecto de la duración

Para cuantificar la magnitud se utilizó la d de Cohen:

$$d = \frac{\bar{x}_{\text{mal}} - \bar{x}_{\text{buen}}}{s_{\text{pooled}}},$$

donde:

$$s_{\text{pooled}} = \sqrt{\frac{(n_{\text{mal}} - 1)s_{\text{mal}}^2 + (n_{\text{buen}} - 1)s_{\text{buen}}^2}{n_{\text{mal}} + n_{\text{buen}} - 2}}.$$

El resultado fue:

$$d = 0.480.$$

La magnitud puede describirse como pequeña a moderada y cercana al umbral convencional de un efecto medio. La diferencia no es únicamente producto del tamaño de la muestra: representa un desplazamiento visible entre las distribuciones de duración.

Sin embargo, existe un solapamiento considerable entre los grupos. Un plazo largo no implica necesariamente que un crédito sea malo y un plazo corto no garantiza un buen

resultado. La duración debe interpretarse junto con la liquidez, el historial, los ahorros y las demás variables del solicitante.

Hallazgo principal. La duración presenta la diferencia marginal más clara entre las variables numéricas evaluadas. Los malos créditos duran, en promedio, alrededor de 5.65 meses más, con un tamaño de efecto cercano a moderado.

9.6 Comparación del monto

El monto presenta una fuerte asimetría positiva y valores elevados en la cola derecha. Por esta razón, la comparación principal se realizó con la prueba U de Mann–Whitney.

Las hipótesis fueron:

H_0 : la distribución del monto es equivalente en ambos grupos,

H_1 : la distribución del monto difiere entre los grupos.

Las medianas observadas fueron:

$$\tilde{x}_{\text{buen}} = 2244 \text{ DM},$$

$$\tilde{x}_{\text{mal}} = 2574.5 \text{ DM}.$$

La diferencia de medianas fue:

$$2574.5 - 2244 = 330.5 \text{ DM}.$$

La prueba produjo:

$$U = 116\,520, \quad p = 0.00592.$$

Como el valor p es menor que 0.05, se rechaza la hipótesis nula. Existe evidencia de una diferencia en la distribución del monto entre buenos y malos créditos.

9.7 Tamaños del efecto del monto

El tamaño del efecto no paramétrico se calculó mediante la correlación biserial de rangos:

$$r_{\text{rb}} = \frac{2U}{n_{\text{mal}}n_{\text{buen}}} - 1.$$

El resultado fue:

$$r_{\text{rb}} = 0.110.$$

El signo positivo indica que los montos del grupo de mal riesgo tienden a ocupar rangos más altos. Su magnitud es pequeña.

Como medida complementaria se calculó la d de Cohen sobre el logaritmo del monto:

$$d_{\log(\text{monto})} = 0.240.$$

Esta medida también indica un efecto pequeño. Por tanto, aunque la diferencia es estadísticamente significativa, el monto por sí solo proporciona una separación limitada entre las clases.

La diferencia observada puede estar relacionada con la duración. El coeficiente de Spearman entre duración y monto fue aproximadamente:

$$\rho = 0.62.$$

Los créditos más altos tienden a distribuirse en plazos más largos. Por ello, una asociación marginal entre monto y riesgo no implica que el monto conserve un efecto independiente al controlar por la duración.

Hallazgo principal. Los malos créditos presentan montos generalmente mayores, pero la magnitud de la diferencia es pequeña. La significancia marginal debe contrastarse con el modelo multivariable antes de atribuir al monto un papel independiente.

9.8 Resumen de los contrastes

La Tabla 18 reúne los resultados principales.

Cuadro 17: Resumen de las pruebas de hipótesis y tamaños de efecto.

Relación	Prueba	Estadístico	p	Tamaño del efecto	Interpretación
Propósito y riesgo	Chi-cuadrado de independencia	$\chi^2(9) = 33.356$	0,000.12	$V = 0.183$	Asociación estadísticamente significativa, pero pequeña.
Duración por clase	t de Welch	$t = 6.470$	< 0.001	$d = 0.480$	Los malos créditos presentan plazos mayores; efecto pequeño a moderado.
Monto por clase	U de Mann–Whitney	$U = 116\,520$	0,005.92	$r_{tb} = 0.110$	Los malos créditos tienden a tener montos mayores; efecto pequeño.
Logaritmo del monto	Medida complementaria	—	—	$d = 0.240$	Diferencia estandarizada pequeña después de transformar la escala.

9.9 Interpretación integrada de la evidencia frecuentista

Las tres relaciones evaluadas presentan evidencia estadística de asociación con el riesgo. Sin embargo, sus magnitudes son diferentes:

- el propósito muestra una asociación global pequeña;
- la duración presenta el efecto numérico marginal más fuerte;
- el monto presenta una diferencia estadísticamente significativa, pero con un efecto pequeño.

Estos resultados responden a comparaciones marginales: cada predictor se analiza por separado. No permiten concluir que propósito, duración o monto mantengan el mismo efecto cuando se controlan simultáneamente las demás características.

En particular, la correlación entre duración y monto puede producir una aparente asociación del monto con el riesgo que disminuya después de incorporar ambas variables en un modelo conjunto.

La regresión logística de la Sección 10 permitirá distinguir entre:

- asociación marginal, observada en comparaciones individuales;
- asociación condicional, estimada manteniendo constantes los demás predictores incluidos en el modelo.

Esta distinción resulta central en ciencia de datos de riesgo de crédito. Una variable puede ser útil para segmentar descriptivamente una cartera y, al mismo tiempo, aportar poca información incremental una vez que el modelo ya conoce otras características relacionadas.

9.10 Supuestos y limitaciones

Los contrastes se apoyan en varios supuestos:

- las observaciones se tratan como registros independientes;
- las etiquetas de riesgo se consideran correctamente definidas;
- la muestra se interpreta como representativa de una población comparable con el dataset original;
- las pruebas evalúan asociación y no causalidad.

La prueba de Welch reduce la dependencia del supuesto de igualdad de varianzas, pero continúa evaluando una diferencia entre medias. La prueba de Mann–Whitney trabaja con rangos y es más robusta frente a la asimetría; sin embargo, no debe interpretarse automáticamente como una prueba exclusiva de medianas cuando las formas de las distribuciones difieren.

Los valores p cuantifican la incompatibilidad de los datos con las hipótesis nulas bajo los modelos asumidos. No expresan la probabilidad de que una hipótesis sea verdadera y no miden la importancia económica de una diferencia.

Por ello, las decisiones se interpretan junto con los tamaños de efecto, las distribuciones observadas y los resultados de los modelos multivariados.

10 Modelo de regresión y diagnóstico

El modelamiento se desarrolló en dos niveles. En primer lugar, se ajustó una regresión lineal múltiple para estudiar la estructura del monto del crédito y cumplir con el análisis de regresión y diagnóstico requerido por el curso. En segundo lugar, se ajustó una regresión logística para estimar la probabilidad de que un registro sea clasificado como mal riesgo.

La regresión lineal tiene un papel auxiliar: permite examinar qué características contractuales y personales están asociadas con el monto otorgado. No constituye el modelo principal de clasificación crediticia. La respuesta de riesgo es binaria y se analiza posteriormente mediante regresión logística.

10.1 Regresión lineal múltiple para el monto del crédito

10.1.1 Especificación del modelo

El monto original presenta una asimetría positiva pronunciada. Por este motivo, la variable dependiente se expresa en escala logarítmica:

$$Y_i = \log(\text{monto}_i).$$

El modelo ajustado fue:

$$\log(\text{monto}_i) = \beta_0 + \beta_1 \text{duracion}_i + \beta_2 \text{tasa_cuota}_i + \beta_3 \text{edad}_i + \varepsilon_i.$$

La especificación incorpora tres dimensiones relevantes de la operación:

- la duración contractual del crédito, expresada en meses;
- el nivel ordinal de la cuota respecto del ingreso disponible;
- la edad del solicitante, expresada en años.

Bajo el modelo clásico se supone:

$$E(\varepsilon_i \mid X_i) = 0,$$

$$\text{Var}(\varepsilon_i \mid X_i) = \sigma^2,$$

y, para la inferencia exacta en muestras finitas:

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

Cada coeficiente representa la variación esperada en el logaritmo del monto asociada con un aumento de una unidad en el predictor correspondiente, manteniendo constantes las demás variables incluidas.

Debido a la transformación logarítmica, la variación porcentual asociada con un coeficiente β_j se obtiene mediante:

$$100 [\exp(\beta_j) - 1] .$$

Esta interpretación es exacta para una variación de una unidad y no debe confundirse con un efecto causal.

10.1.2 Ajuste global

El modelo se estimó sobre las 1000 observaciones mediante mínimos cuadrados ordinarios. La prueba global evalúa:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0,$$

frente a:

$$H_1 : \text{al menos uno de los coeficientes es distinto de cero.}$$

El resultado fue:

$$F(3, 996) = 386.4, \quad p = 2,04 \times 10^{-166}.$$

Por tanto, se rechaza la hipótesis nula global. Las variables incluidas aportan información conjunta sobre el logaritmo del monto.

El coeficiente de determinación fue:

$$R^2 = 0.538,$$

mientras que el coeficiente ajustado fue:

$$R^2_{\text{ajustado}} = 0.537.$$

El modelo explica aproximadamente el 53.8 % de la variabilidad observada en $\log(\text{monto})$. El valor restante corresponde a características no incluidas, variabilidad individual, posibles relaciones no lineales y error aleatorio.

10.1.3 Coeficientes estimados

La Tabla 19 presenta los coeficientes clásicos.

Cuadro 18: Coeficientes del modelo OLS para el logaritmo del monto.

Variable	Coeficiente	Error estándar	Estadístico t	p	IC del 95 %
Intercepto	7,486.0	0,074.2	100,915	< 0.001	[7.340, 7.632]
Duración	0,043.1	0,001.4	30,970	< 0.001	[0.040, 0.046]
Tasa de la cuota	-0,247.6	0,015.0	-16,482	< 0.001	[-0.277, -0.218]
Edad	0,003.9	0,001.5	2,624	0,008.8	[0.001, 0.007]

Manteniendo constantes las demás variables:

- un mes adicional de duración se asocia con un incremento aproximado del 4.4 % en el monto esperado;
- un aumento de una unidad en la escala de `tasa_cuota` se asocia con una reducción aproximada del 21.9 % en el monto esperado;

- un año adicional de edad se asocia con un incremento aproximado del 0.4 % en el monto esperado.

La duración presenta la asociación positiva de mayor magnitud. Esto es coherente con la estructura financiera de una operación: los montos mayores suelen distribuirse en plazos más largos para reducir la cuota periódica.

La asociación negativa de `tasa_cuota` también es económicamente plausible. Una mayor carga relativa de pago puede limitar el monto que la entidad está dispuesta a conceder. Sin embargo, la variable está registrada como una escala ordinal de 1 a 4 y no como un porcentaje exacto. Por ello, el cambio entre niveles se interpreta como un contraste dentro de la codificación disponible, no como una variación de un punto porcentual del ingreso.

La edad presenta una asociación estadísticamente significativa, pero de magnitud reducida. Su importancia práctica es considerablemente menor que la de la duración y la carga de la cuota.

Hallazgo principal. La duración y la carga de la cuota concentran la mayor parte de la señal explicativa del modelo del monto. La edad aporta información adicional, pero su asociación condicional es pequeña.

10.2 Diagnóstico de multicolinealidad

La multicolinealidad se evaluó mediante el factor de inflación de la varianza:

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 corresponde al coeficiente de determinación obtenido al regresar el predictor X_j sobre los demás predictores.

Los resultados se presentan en la Tabla 20.

Cuadro 19: Factores de inflación de la varianza del modelo OLS.

Variable	VIF
Duración	1,007
Tasa de la cuota	1,009
Edad	1,005

Los valores se encuentran muy próximos a uno. No se observa una relación lineal fuerte entre los tres predictores del modelo y, por tanto, no hay evidencia de multicolinealidad relevante en esta especificación.

Este resultado no contradice la correlación observada entre duración y monto, porque el monto es la variable dependiente. El VIF evalúa la relación entre los predictores: duración, tasa de la cuota y edad.

10.3 Diagnóstico gráfico de los residuos

La Figura 6 presenta los cuatro gráficos diagnósticos requeridos.

Figura 6. Diagnósticos del modelo OLS para log(monto)




Figura 6: Diagnósticos del modelo OLS para log(monto): residuos frente a valores ajustados, gráfico Q–Q, gráfico Scale–Location y residuos estandarizados frente a leverage.

El gráfico de residuos frente a valores ajustados no muestra una curvatura dominante, aunque se observan pequeñas variaciones locales en la línea suavizada. La dispersión alrededor de cero es razonablemente estable.

El gráfico Q–Q presenta una alineación adecuada en la región central, con desviaciones moderadas en las colas. Esto sugiere una aproximación normal razonable para la mayor parte de los residuos, aunque no una normalidad estricta.

El gráfico Scale–Location tampoco presenta una forma de embudo marcada. La línea suavizada muestra variaciones leves, pero no una expansión sistemática de la varianza a lo largo de los valores ajustados.

Finalmente, el gráfico de residuos frente a leverage permite identificar observaciones que combinan valores poco habituales de los predictores con residuos elevados. La distancia de Cook máxima fue:

$$D_{\text{máx}} = 0,047.6.$$

Utilizando el umbral exploratorio:

$$\frac{4}{n} = \frac{4}{1000} = 0.004,$$

se identificaron 52 observaciones por encima de dicho valor. Este umbral es deliberadamente sensible y funciona como una señal para revisión, no como una regla automática de exclusión.

La distancia máxima permanece muy por debajo de uno, por lo que no se observa una única operación con influencia extrema sobre el ajuste. Las observaciones señaladas se conservaron porque corresponden a registros válidos y su eliminación no estaba justificada por un error documentado.

10.4 Normalidad de los residuos

La normalidad se evaluó formalmente mediante la prueba de Shapiro–Wilk:

H_0 : los residuos siguen una distribución normal,

H_1 : los residuos no siguen una distribución normal.

El resultado fue:

$$W = 0,995.1, \quad p = 0,002.75.$$

Al nivel de significancia de 0.05, se rechaza la normalidad estricta. Sin embargo, el valor de W es cercano a uno y el gráfico Q–Q muestra que las principales desviaciones se concentran en las colas.

Con $n = 1000$, las pruebas de normalidad tienen capacidad para detectar desviaciones pequeñas que no necesariamente producen un deterioro práctico importante de la inferencia. Por esta razón, el resultado se interpreta junto con los gráficos, el tamaño de la muestra y la comparación posterior de los errores estándar clásicos y robustos.

10.5 Homocedasticidad: prueba de Breusch–Pagan

La constancia de la varianza se evaluó mediante:

$$H_0 : \text{Var}(\varepsilon_i | X_i) = \sigma^2,$$

$$H_1 : \text{Var}(\varepsilon_i | X_i) \text{ no es constante.}$$

La prueba de Breusch–Pagan produjo:

$$LM = 5,888, \quad p = 0,117.16,$$

y la versión basada en F :

$$F = 1,967, \quad p = 0,117.33.$$

Como ambos valores p son superiores a 0.05, no se rechaza la hipótesis de varianza constante. La homocedasticidad constituye una aproximación razonable para esta especificación.

No rechazar H_0 no demuestra que la varianza sea exactamente constante. Indica que el test no encontró evidencia suficiente de heterocedasticidad con los datos y la forma funcional utilizadas.

10.6 Inferencia robusta HC3

Como comprobación de sensibilidad, se recalcularon los errores estándar mediante el estimador robusto HC3. Esta corrección mantiene los coeficientes y predicciones, pero modifica la matriz de covarianza utilizada en la inferencia.

Cuadro 20: Comparación entre la inferencia clásica y la corrección robusta HC3.

Variable	Coefficiente	EE clásico	EE HC3	p HC3
Intercepto	7,486.0	0,074.2	0,074.8	< 0.001
Duración	0,043.1	0,001.4	0,001.5	< 0.001
Tasa de la cuota	-0,247.6	0,015.0	0,015.6	< 0.001
Edad	0,003.9	0,001.5	0,001.6	0,014.4

Los errores HC3 son ligeramente mayores, pero las conclusiones no cambian. Duración, tasa de la cuota y edad mantienen asociaciones estadísticamente significativas.

La estabilidad frente a HC3 respalda que los resultados no dependen exclusivamente de la matriz de covarianza clásica. La edad continúa siendo significativa, aunque con menor evidencia que las otras dos variables.

10.7 Validación cruzada de cinco particiones

La capacidad de generalización se evaluó mediante validación cruzada k -fold con:

$$k = 5.$$

La muestra se dividió aleatoriamente en cinco grupos. En cada iteración, cuatro particiones se utilizaron para ajustar el modelo y la restante para evaluarlo. La semilla utilizada fue SEED = 2026.

El desempeño se midió mediante R^2 y RMSE en la escala de $\log(\text{monto})$.

Cuadro 21: Resultados de validación cruzada del modelo OLS.

Partición	R^2	RMSE
1	0,532.1	0,577.6
2	0,497.2	0,529.2
3	0,594.3	0,495.9
4	0,543.9	0,486.1
5	0,490.1	0,556.1
Media	0,531.5	0,529.0
Desviación estándar de R^2	0,041.8	—

El R^2 medio fuera de muestra fue:

$$\overline{R^2}_{CV} = 0,531.5 \pm 0,041.8.$$

El RMSE medio fue:

$$RMSE_{CV} = 0,529.0$$

en la escala logarítmica.

El desempeño de validación es muy próximo al obtenido con la muestra completa:

$$R^2_{\text{completo}} = 0,537.9.$$

La diferencia entre ambos valores es reducida, lo que indica que el modelo mantiene una capacidad explicativa estable en observaciones no utilizadas durante cada ajuste. No se observa evidencia importante de sobreajuste dentro del esquema de validación aplicado.

10.8 Conclusión del modelo lineal

El modelo OLS proporciona una representación parsimoniosa e interpretable de la estructura del monto. La duración, la carga de la cuota y la edad explican conjuntamente cerca del 54 % de la variabilidad de su logaritmo.

La duración presenta la asociación positiva dominante. La tasa de la cuota mantiene una asociación negativa importante y la edad aporta una señal positiva pequeña. Los VIF cercanos a uno descartan problemas relevantes de multicolinealidad entre los predictores seleccionados.

Los diagnósticos no muestran evidencia de heterocedasticidad y la inferencia robusta HC3 conserva las conclusiones. La prueba de Shapiro–Wilk detecta una desviación respecto de la normalidad estricta, pero el comportamiento gráfico, el tamaño de la muestra y la estabilidad de los errores robustos indican que dicha desviación no modifica de forma sustantiva la lectura del modelo.

Finalmente, la validación cruzada muestra un desempeño cercano al ajuste completo. El modelo es útil para comprender la relación entre el plazo, la capacidad de pago aproximada, la edad y el monto otorgado.

No obstante, este resultado no responde todavía qué solicitantes tienen mayor probabilidad de mal crédito. Esa pregunta requiere un modelo con respuesta binaria, desarrollado en el bloque siguiente mediante regresión logística.

10.9 Regresión logística para la probabilidad de mal crédito

La segunda parte del modelamiento utiliza como respuesta la variable:

$$Y_i = \text{mal_credito}_i,$$

donde:

$$Y_i = \begin{cases} 1, & \text{si el registro corresponde a mal riesgo,} \\ 0, & \text{si corresponde a buen riesgo.} \end{cases}$$

Sea:

$$p_i = \Pr(Y_i = 1 \mid \mathbf{x}_i)$$

la probabilidad condicional de que la observación i sea clasificada como mal crédito. La regresión logística relaciona esta probabilidad con los predictores mediante:

$$\text{logit}(p_i) = \log\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta}.$$

De forma equivalente:

$$p_i = \frac{\exp(\beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta})}{1 + \exp(\beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta})}.$$

El modelo estima probabilidades individuales de mal riesgo. La transformación de esas probabilidades en una decisión binaria requiere un umbral, cuya selección se analiza posteriormente.

10.9.1 Diseño de entrenamiento y prueba

El conjunto de datos se dividió de forma estratificada en:

70 % para entrenamiento y 30 % para prueba.

La partición resultante fue:

$$n_{\text{train}} = 700, \quad n_{\text{test}} = 300.$$

La tasa de mal crédito se mantuvo en 30.0 % en ambos subconjuntos. Por tanto, el conjunto de entrenamiento contiene 210 malos créditos y el conjunto de prueba contiene 90.

La estratificación permite comparar el desempeño sin que una variación accidental de la prevalencia modifique de manera importante las métricas. El modelo se ajustó exclusivamente con el conjunto de entrenamiento. El conjunto de prueba permaneció separado hasta la evaluación final.

La semilla utilizada fue:

$$\text{SEED} = 2026.$$

10.9.2 Especificación del modelo

La especificación incorporó variables contractuales, antecedentes crediticios y señales de estabilidad financiera:

$$\begin{aligned} \text{logit}(p_i) = & \beta_0 + \beta_1 \text{duracion}_i + \beta_2 \text{log_monto}_i + \beta_3 \text{tasa_cuota}_i + \beta_4 \text{edad}_i \\ & + \text{estado de cuenta} + \text{historial crediticio} + \text{ahorros} \\ & + \text{antigüedad laboral} + \text{vivienda} + \text{otros planes de pago}. \end{aligned}$$

Las variables categóricas se introdujeron mediante indicadores, dejando una categoría de referencia en cada grupo. Las referencias fueron:

- estado de cuenta: A11, saldo menor que cero;
- historial crediticio: A30, sin créditos previos o todos pagados;
- ahorros: A61, menos de 100 DM;
- empleo actual: A71, desempleado;
- vivienda: A151, alquilada;
- otros planes de pago: A141, banco.

Los coeficientes se estimaron mediante máxima verosimilitud con `statsmodels`. El algoritmo convergió correctamente y el modelo contiene 24 coeficientes, incluido el intercepto.

El pseudo- R^2 de McFadden en entrenamiento fue:

$$R_{\text{McFadden}}^2 = 0.2202.$$

Este valor no debe interpretarse como el porcentaje de variabilidad explicada y no es comparable directamente con el R^2 de una regresión OLS. Se utiliza como una medida relativa de mejora frente a un modelo que solo contiene intercepto.

10.10 Interpretación mediante odds ratios

En una regresión logística, el coeficiente β_j representa un cambio en el logaritmo de las *odds*. Para facilitar la interpretación se utiliza:

$$OR_j = \exp(\beta_j).$$

Cuando $OR_j > 1$, las *odds* de mal crédito aumentan. Cuando $OR_j < 1$, disminuyen. En ambos casos, la comparación mantiene constantes los demás predictores del modelo.

Es importante distinguir *odds* de probabilidad. Un aumento del 20 % en las *odds* no equivale necesariamente a un aumento de veinte puntos porcentuales en la probabilidad, porque el efecto sobre la probabilidad depende de su nivel inicial.

10.10.1 Predictores numéricos

La Tabla 23 presenta los resultados de los predictores numéricos.

Cuadro 22: Odds ratios de los predictores numéricos del modelo logístico.

Predictor	OR	IC del 95 %	p
Duración	1,039.0	[1.0160, 1.0625]	0,000.8
Logaritmo del monto	1,065.8	[0.7483, 1.5181]	0,723.8
Tasa de la cuota	1,228.3	[1.0085, 1.4959]	0,040.9
Edad	0,997.2	[0.9775, 1.0172]	0,779.8

Manteniendo constantes las demás variables, cada mes adicional de duración se asocia con un aumento aproximado del 3.9 % en las *odds* de mal crédito:

$$100(1.0390 - 1) = 3.9 \, \%.$$

El intervalo de confianza se mantiene por encima de uno y el valor p es inferior a 0.05. La duración conserva, por tanto, una asociación positiva después de controlar por las demás características.

Una unidad adicional en la escala de `tasa_cuota` se asocia con un incremento aproximado del 22.8 % en las *odds*. Esta interpretación se refiere a un cambio entre niveles de una escala ordinal, no a un incremento de un punto porcentual del ingreso.

En contraste, `log_monto` deja de ser estadísticamente significativo:

$$OR = 1.0658, \quad p = 0.7238.$$

El monto mostró una diferencia marginal entre buenos y malos créditos, pero no aporta evidencia de una asociación independiente una vez que el modelo incorpora duración, liquidez, historial y otras variables. Parte de su señal inicial parece estar compartida con la duración del préstamo.

La edad tampoco presenta evidencia de una asociación condicional dentro de esta especificación.

10.10.2 Categorías con evidencia estadística

La Tabla 24 resume las categorías cuyo intervalo del 95 % no contiene el valor uno.

Cuadro 23: Categorías con asociación estadísticamente significativa en el modelo logístico.

Variable	Categoría frente a referencia	OR	IC del 95 %	<i>p</i>
Ahorros	A64: 1000 DM o más frente a A61	0,161.7	[0.0349, 0.7495]	0,019.9
Estado de cuenta	A14: sin cuenta corriente frente a A11	0,180.3	[0.1079, 0.3014]	< 0.001
Historial crediticio	A34: cuenta crítica u otros créditos frente a A30	0,241.3	[0.0910, 0.6403]	0,004.3
Estado de cuenta	A13: saldo de 200 DM o más frente a A11	0,312.1	[0.1384, 0.7038]	0,005.0
Empleo actual	A74: entre cuatro y siete años frente a A71	0,403.7	[0.1632, 0.9987]	0,049.7
Ahorros	A65: desconocido o sin cuenta frente a A61	0,430.3	[0.2421, 0.7647]	0,004.1
Vivienda	A152: propia frente a A151	0,586.8	[0.3552, 0.9694]	0,037.4
Estado de cuenta	A12: saldo entre 0 y 200 DM frente a A11	0,604.1	[0.3776, 0.9665]	0,035.5

El estado de la cuenta corriente presenta un gradiente coherente respecto de la categoría de saldo negativo. Los perfiles con saldo positivo y los registros sin una cuenta corriente codificada muestran menores *odds* que el grupo de referencia.

El resultado de A14 no implica que carecer de cuenta corriente sea, en términos generales, una condición financiera favorable. La comparación se realiza específicamente frente a solicitantes con saldo negativo. Además, la categoría histórica puede condensar perfiles heterogéneos que no pueden separarse con la documentación disponible.

Los niveles altos de ahorro presentan menores *odds* que el grupo con menos de 100 DM. La categoría A65 combina ausencia de cuenta e información desconocida, por lo que su asociación debe interpretarse con cautela.

La vivienda propia también se asocia con menores *odds* frente a la vivienda alquilada. La antigüedad laboral de cuatro a siete años presenta una asociación protectora, aunque su valor $p = 0.0497$ y el límite superior del intervalo, próximo a uno, indican evidencia débil y sensible al redondeo.

El resultado del historial A34 debe leerse únicamente como un contraste condicional respecto de A30. La denominación histórica de las categorías no permite convertir directamente ese coeficiente en una regla general de aprobación.




Figura 7: Odds ratios e intervalos de confianza del 95 % del modelo logístico. La línea vertical representa ausencia de asociación en la escala de odds ratios.

La Figura 7 muestra simultáneamente la magnitud, dirección e incertidumbre de todos los términos. Los intervalos amplios de algunas categorías reflejan tamaños de grupo reducidos y menor precisión.

Hallazgo principal. La duración mantiene la asociación numérica más consistente con el mal crédito. El estado de cuenta, los ahorros, el historial, la vivienda y la carga de la cuota también aportan información condicional. El monto pierde significancia al controlar por estas variables.

10.11 Capacidad discriminativa

La calidad de un modelo de riesgo no se resume en sus coeficientes. Es necesario evaluar si las probabilidades estimadas ordenan adecuadamente los casos de buen y mal crédito en observaciones no utilizadas durante el ajuste.

La métrica principal independiente del umbral fue el área bajo la curva ROC:

$$AUC_{\text{test}} = 0.7740.$$

Este valor puede interpretarse como la probabilidad de que, al elegir al azar un mal crédito y un buen crédito del conjunto de prueba, el modelo asigne una puntuación de riesgo mayor al primero.

El resultado indica una capacidad discriminativa claramente superior al azar, aunque lejos de una separación perfecta. Persisten buenos y malos créditos con probabilidades similares.

También se calculó el estadístico de Kolmogorov–Smirnov utilizado en *credit scoring*:

$$KS = \max_t [TPR(t) - FPR(t)] .$$

El resultado fue:

$$KS = 0.4810,$$

alcanzado alrededor del umbral:

$$t = 0.369.$$

Este resultado muestra una separación apreciable entre las distribuciones de puntajes de ambas clases. Sin embargo, el umbral que maximiza KS no tiene por qué minimizar el costo económico de clasificación.

La AUC evalúa capacidad de ordenamiento. No informa por sí sola si las probabilidades están calibradas, cuál es la rentabilidad de la política crediticia ni qué umbral debe utilizarse.

10.12 Validación cruzada del modelo logístico

La estabilidad se examinó mediante validación cruzada estratificada de cinco particiones. Dentro de cada partición, las variables categóricas se codificaron mediante indicadores y las numéricas se estandarizaron usando exclusivamente la información del conjunto de entrenamiento correspondiente.

Esta construcción evita que el preprocesamiento utilice información de la partición de validación.

Los resultados fueron:

Cuadro 24: ROC–AUC por partición en la validación cruzada del modelo logístico.

Partición	ROC–AUC
1	0,778.5
2	0,774.4
3	0,801.3
4	0,748.5
5	0,739.9
Media	0,768.5
Desviación estándar	0,022.1

La media de validación fue:

$$\overline{AUC}_{CV} = 0.7685 \pm 0.0221.$$

La proximidad entre la AUC de prueba y la media de validación cruzada:

$$0.7740 \approx 0.7685$$

indica un desempeño estable entre particiones. No se observa una brecha importante que sugiera sobreajuste bajo el diseño de evaluación utilizado.

10.13 Clasificación con el umbral estándar

El umbral convencional clasifica una observación como mal riesgo cuando:

$$\hat{p}_i \geq 0.50.$$

Con este umbral, la matriz de confusión del conjunto de prueba fue:

	Predicho bueno	Predicho malo
Real bueno	180	30
Real malo	48	42

Por tanto:

$$TN = 180, \quad FP = 30, \quad FN = 48, \quad TP = 42.$$

Las métricas fueron:

$$\text{accuracy} = 0.7400,$$

$$\text{precision} = 0.5833,$$

$$\text{recall} = 0.4667,$$

$$F_1 = 0.5185,$$

$$\text{especificidad} = \frac{180}{180 + 30} = 0.8571.$$

Aunque la exactitud alcanza el 74.0 %, el modelo identifica menos de la mitad de los malos créditos. De los 90 casos de mal riesgo, 48 serían clasificados como buenos.

Este resultado ilustra por qué la exactitud no puede utilizarse como único criterio: la política favorece la especificidad, pero conserva demasiados falsos negativos para una matriz de costos que penaliza ese error cinco veces más.

10.14 Selección del umbral bajo costos asimétricos

La matriz de costos asigna:

$$C_{FN} = 5, \quad C_{FP} = 1.$$

Para una observación con probabilidad estimada p , el costo esperado de clasificarla como buen riesgo es:

$$C(\text{predecir bueno}) = C_{FN}p.$$

El costo esperado de clasificarla como mal riesgo es:

$$C(\text{predecir malo}) = C_{FP}(1 - p).$$

La decisión de menor costo clasifica como mal riesgo cuando:

$$C_{FP}(1 - p) \leq C_{FN}p.$$

Al despejar p :

$$p \geq \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

Por tanto, el umbral teórico es:

$$t^* = \frac{1}{1 + 5} = \frac{1}{6} \approx 0.1667.$$

Esta regla supone que los costos representan adecuadamente el problema y que las probabilidades producidas por el modelo están razonablemente calibradas. La AUC por sí sola no permite comprobar esta segunda condición.

El umbral se deriva de la matriz de costos y no de la búsqueda del mejor resultado en el conjunto de prueba. La curva empírica de costos se utiliza únicamente como diagnóstico posterior.




Figura 8: Costo total de clasificación en el conjunto de prueba según el umbral. Se muestran el umbral estándar, el umbral teórico derivado de la matriz 5 : 1 y el mínimo empírico.

El costo empírico mínimo se observa alrededor de:

$$t_{\text{emp}} = 0.16,$$

con un costo de 157 unidades. Este valor es prácticamente igual al umbral teórico 0.1667, cuyo costo es 158. La diferencia de una unidad no justifica reemplazar la regla derivada de costos por un umbral optimizado sobre la misma muestra de prueba.

Seleccionar t_{emp} como política final usando las etiquetas del test introduciría optimismo. En un desarrollo real, cualquier ajuste empírico del umbral debería efectuarse en validación y confirmarse sobre un conjunto final independiente.

10.15 Comparación de las políticas de decisión

La Tabla 26 compara ambos puntos de operación.

Cuadro 25: Desempeño del modelo logístico bajo los umbrales 0.50 y 1/6.

Umbral	TP	FP	FN	TN	Accuracy	Precisión	Recall	Especificidad	F_1	Costo
0.50	42	30	48	180	0,740.0	0,583.3	0,466.7	0,857.1	0,518.5	270
1/6	80	108	10	102	0,606.7	0,425.5	0,888.9	0,485.7	0,575.5	158

Al reducir el umbral:

- los verdaderos positivos aumentan de 42 a 80;

- los falsos negativos disminuyen de 48 a 10;
- el recall aumenta de 46.7 % a 88.9 %;
- los falsos positivos aumentan de 30 a 108;
- la precisión disminuye de 58.3 % a 42.6 %;
- la especificidad disminuye de 85.7 % a 48.6 %;
- la exactitud disminuye de 74.0 % a 60.7 %;
- el F_1 aumenta de 0.5185 a 0.5755.

La política basada en costos es más conservadora. Identifica una mayor proporción de los créditos riesgosos a cambio de marcar también como riesgosos a más clientes que habrían sido buenos pagadores.

La reducción de falsos negativos es:

$$48 - 10 = 38.$$

El costo evitado por estos casos es:

$$38 \times 5 = 190.$$

El incremento de falsos positivos es:

$$108 - 30 = 78,$$

con un costo adicional de 78. El ahorro neto es:

$$190 - 78 = 112.$$

En consecuencia, el costo total disminuye de:

$$270 \text{ a } 158,$$

lo que equivale a una reducción de:

$$\frac{270 - 158}{270} \times 100 = 41.5 \%$$

El costo medio por observación disminuye de 0.9000 a 0.5267.

Figura 9. ROC y clasificación bajo umbral estándar vs. umbral de costo




Figura 9: Curva ROC y matrices de confusión del modelo logístico con el umbral estándar y el umbral derivado de la matriz de costos.

La Figura 9 muestra que la curva ROC no cambia al modificar el umbral: la capacidad de ordenamiento pertenece al modelo. Lo que cambia es el punto de operación elegido sobre esa curva y, por tanto, el equilibrio entre falsos positivos y falsos negativos.

Hallazgo principal. El umbral 0.50 ofrece mayor exactitud y especificidad, pero omite más de la mitad de los malos créditos. Bajo la matriz de costos 5 : 1, el umbral 1/6 reduce el costo total en aproximadamente 41.5 % al priorizar la detección del riesgo.

10.16 Lectura operativa del modelo

Los resultados permiten diferenciar tres propiedades del sistema:

1. **Asociación.** Los odds ratios identifican variables que mantienen una relación condicional con la clase de riesgo.
2. **Discriminación.** La AUC y el KS evalúan la capacidad para ordenar solicitantes desde menor hasta mayor riesgo.
3. **Decisión.** El umbral transforma las probabilidades en una política de clasificación y determina el costo de los errores.

Un modelo puede discriminar razonablemente y aun así producir una política inadecuada si se utiliza un umbral incompatible con los costos del negocio. De forma similar, un umbral conservador puede reducir pérdidas por falsos negativos, pero también aumentar rechazos innecesarios.

La matriz 5 : 1 procede de la documentación del dataset y permite desarrollar el ejercicio de decisión. No representa una estimación económica completa de una institución. En una aplicación real, el costo de un falso negativo debería incorporar exposición al incumplimiento, pérdida dado incumplimiento, recuperación y costos de cobranza. El costo de un falso positivo debería considerar margen financiero perdido, costos de adquisición y valor futuro del cliente.

La elección final también requeriría:

- evaluar la calibración de las probabilidades;
- validar temporalmente el modelo;
- comprobar la estabilidad de las variables y categorías;
- analizar equidad y posibles efectos adversos;
- establecer una zona de revisión manual para probabilidades cercanas al punto de corte.

Por tanto, el modelo debe considerarse una herramienta de apoyo para priorizar y revisar solicitudes, no un mecanismo autónomo listo para aprobar o rechazar créditos.

10.17 Conclusión del modelamiento

El modelo OLS mostró que la duración y la carga de la cuota explican una parte importante de la estructura del monto otorgado, con un desempeño estable en validación cruzada.

La regresión logística alcanzó una AUC de 0.7740 en prueba y una AUC media de 0.7685 en validación cruzada. Esta consistencia indica una capacidad discriminativa estable y sin evidencia importante de sobreajuste bajo las particiones evaluadas.

Los factores condicionales más relevantes fueron el estado de la cuenta, la duración, el historial crediticio, el nivel de ahorros, la vivienda y la carga de la cuota. El monto mostró una asociación marginal con el riesgo, pero perdió significancia al controlar simultáneamente por los demás predictores.

Finalmente, la comparación de umbrales mostró que la política de decisión no debe basarse exclusivamente en la exactitud. Bajo el costo asimétrico 5 : 1, reducir el umbral a 1/6 aumenta sustancialmente la detección de malos créditos y reduce el costo total, aunque a cambio de más falsos positivos.

11 Análisis bayesiano

El análisis bayesiano complementa la inferencia frecuentista mediante una representación probabilística de la incertidumbre sobre los parámetros. Se desarrollaron dos ejercicios:

1. un modelo Beta–Binomial conjugado para la proporción global de malos créditos;
2. una regresión logística bayesiana estimada mediante Metropolis–Hastings para estudiar la distribución posterior del coeficiente de duración.

El primer ejercicio permite obtener la distribución posterior de forma analítica y evaluar la sensibilidad de los resultados frente a distintas distribuciones previas. El segundo requiere simulación MCMC porque la regresión logística no dispone de una posterior conjugada de forma cerrada.

11.1 Modelo Beta–Binomial para la tasa de mal crédito

En el enfoque frecuentista, la tasa de mal crédito se trató como un parámetro fijo pero desconocido. A partir de:

$$x = 300, \quad n = 1000,$$

se obtuvo la estimación:

$$\hat{p} = \frac{x}{n} = 0.300.$$

En el enfoque bayesiano, la incertidumbre sobre p se representa mediante una distribución de probabilidad. Después de observar los datos, la distribución previa se actualiza aplicando el teorema de Bayes:

$$\pi(p \mid x) \propto L(x \mid p)\pi(p),$$

donde:

- $\pi(p)$ es la distribución previa o *prior*;
- $L(x \mid p)$ es la verosimilitud aportada por los datos;
- $\pi(p \mid x)$ es la distribución posterior.

El resultado no es únicamente una estimación puntual, sino una distribución completa que describe qué valores de p son más compatibles con el prior y la información observada.

11.1.1 Verosimilitud binomial

Sea X el número de malos créditos observados entre n registros. El modelo de muestreo es:

$$X \mid p \sim \text{Binomial}(n, p).$$

La función de probabilidad es:

$$\Pr(X = x \mid p) = \binom{n}{x} p^x (1 - p)^{n-x}.$$

Para la inferencia sobre p , los términos que no dependen del parámetro pueden omitirse. La verosimilitud queda expresada como:

$$L(p \mid x) \propto p^x (1 - p)^{n-x}.$$

En el problema analizado:

$$L(p \mid x) \propto p^{300} (1 - p)^{700}.$$

11.1.2 Distribución previa Beta

Se asigna a la tasa una distribución previa:

$$p \sim \text{Beta}(\alpha, \beta).$$

Su densidad es:

$$\pi(p) = \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1}, \quad 0 < p < 1,$$

donde $B(\alpha, \beta)$ es la función Beta.

Omitiendo la constante de normalización:

$$\pi(p) \propto p^{\alpha-1} (1-p)^{\beta-1}.$$

La media previa es:

$$E[p] = \frac{\alpha}{\alpha + \beta}.$$

Los parámetros α y β controlan tanto la localización como la concentración de la información previa.

11.1.3 Posterior conjugada

Al combinar el prior y la verosimilitud:

$$\begin{aligned} \pi(p | x) &\propto p^x (1-p)^{n-x} p^{\alpha-1} (1-p)^{\beta-1} \\ &\propto p^{\alpha+x-1} (1-p)^{\beta+n-x-1}. \end{aligned}$$

Este núcleo corresponde nuevamente a una distribución Beta. Por tanto:

$$p | X = x \sim \text{Beta}(\alpha + x, \beta + n - x).$$

La actualización puede interpretarse como la incorporación de x malos créditos al primer parámetro y $n - x$ buenos créditos al segundo:

$$\alpha_{\text{post}} = \alpha + x,$$

$$\beta_{\text{post}} = \beta + n - x.$$

Esta propiedad se denomina conjugación. Permite obtener la posterior analíticamente, sin recurrir a métodos de simulación.

11.2 Resúmenes de la distribución posterior

Para cada prior se calcularon tres resúmenes: la media posterior, la estimación MAP y el intervalo creíble del 95 %.

11.2.1 Media posterior

La media posterior es:

$$E[p \mid x] = \frac{\alpha + x}{\alpha + \beta + n}.$$

Esta cantidad representa el valor esperado de la tasa después de combinar la información previa con los datos.

11.2.2 Estimación MAP

La estimación de máxima densidad posterior es:

$$\hat{p}_{\text{MAP}} = \frac{\alpha + x - 1}{\alpha + \beta + n - 2},$$

siempre que los dos parámetros posteriores sean mayores que uno.

El MAP identifica el valor de p donde la densidad posterior alcanza su máximo.

11.2.3 Intervalo creíble

El intervalo creíble central del 95 % se obtiene con los cuantiles 0.025 y 0.975 de la posterior:

$$\Pr(p_{\text{inf}} \leq p \leq p_{\text{sup}} \mid x) = 0.95.$$

A diferencia de un intervalo de confianza frecuentista, este intervalo permite una interpretación probabilística directa: condicionados al prior y a los datos observados, la probabilidad posterior de que p se encuentre entre ambos límites es del 95 %.

11.3 Distribuciones previas evaluadas

Se compararon tres priors con distintos niveles de información.

11.3.1 Prior uniforme

El primer modelo utiliza:

$$p \sim \text{Beta}(1, 1).$$

Esta distribución es uniforme en el intervalo $[0, 1]$:

$$\pi(p) = 1.$$

Antes de observar los datos, asigna la misma densidad a cualquier valor posible de la tasa. Se utiliza como una especificación inicial poco informativa.

La posterior resultante es:

$$p \mid x \sim \text{Beta}(301, 701).$$

11.3.2 Prior de Jeffreys

El segundo modelo utiliza:

$$p \sim \text{Beta}(0.5, 0.5).$$

El prior de Jeffreys es una alternativa no informativa construida a partir de la información de Fisher del modelo binomial. Su densidad asigna mayor peso a los extremos del intervalo que el prior uniforme.

La posterior es:

$$p \mid x \sim \text{Beta}(300.5, 700.5).$$

Su inclusión permite comprobar si una definición no informativa diferente produce cambios apreciables en la inferencia.

11.3.3 Prior informativo débil

El tercer modelo utiliza:

$$p \sim \text{Beta}(6, 18).$$

Su media previa es:

$$E[p] = \frac{6}{6 + 18} = 0.25.$$

La concentración total es:

$$\alpha + \beta = 24.$$

Este prior representa una expectativa inicial de que la tasa se encuentre alrededor del 25 %, pero con una concentración pequeña frente a las 1000 observaciones disponibles. Por ello, se considera informativo débil.

La posterior resultante es:

$$p \mid x \sim \text{Beta}(306, 718).$$

El propósito de este prior no es imponer una tasa de 25 %, sino evaluar cuánto se desplaza la inferencia cuando se incorpora una expectativa previa moderadamente distinta de la tasa observada.

11.4 Resultados posteriores

La Tabla 27 presenta los resultados para los tres priors.

Cuadro 26: Resultados del modelo Beta–Binomial bajo diferentes distribuciones previas.

Prior	Posterior	MAP	Media	Intervalo creíble del 95 %
Beta(1, 1), uniforme	Beta(301, 701)	0,300.0	0,300.4	[0.2724, 0.3291]
Beta(0.5, 0.5), Jeffreys	Beta(300.5, 700.5)	0,299.8	0,300.2	[0.2722, 0.3289]
Beta(6, 18), informativo débil	Beta(306, 718)	0,298.4	0,298.8	[0.2712, 0.3272]

Los tres modelos producen resultados muy próximos. Las estimaciones MAP se encuentran entre:

$$0.2984 \quad \text{y} \quad 0.3000,$$

mientras que las medias posteriores se sitúan entre:

$$0.2988 \quad \text{y} \quad 0.3004.$$

El prior uniforme produce un MAP de 0.3000, coincidente con la estimación frecuentista. El prior de Jeffreys genera un resultado casi idéntico.

El prior Beta(6, 18) desplaza ligeramente la posterior hacia su media previa de 0.25. Sin embargo, la media posterior solo disminuye hasta 0.2988, lo que muestra que la influencia del prior es reducida frente al tamaño de la muestra.

11.5 Sensibilidad al prior

La Figura 10 compara las distribuciones previas y posteriores.

Figura 10. Modelo Beta-Binomial: sensibilidad al prior y comparación frecuentista




Figura 10: Sensibilidad del modelo Beta–Binomial a la elección del prior. El panel izquierdo muestra las tres distribuciones previas. El panel derecho presenta las posteriores, la estimación frecuentista y el intervalo de Wilson del 95 %.

En el panel izquierdo, los priors presentan formas claramente diferentes. El uniforme asigna densidad constante, Jeffreys concentra más densidad cerca de cero y uno, y el prior informativo concentra su masa alrededor de valores próximos a 0.25.

Después de observar los 1000 registros, las tres posteriores se superponen casi completamente. La evidencia contenida en los datos domina las diferencias entre las distribuciones previas.

La amplitud de los intervalos creíbles también es muy similar. Entre el límite inferior más bajo y el más alto existe una diferencia de apenas:

$$0.2724 - 0.2712 = 0.0012,$$

equivalente a 0.12 puntos porcentuales. Entre los límites superiores, la diferencia máxima es:

$$0.3291 - 0.3272 = 0.0019,$$

equivalente a 0.19 puntos porcentuales.

Estas variaciones no modifican la conclusión sustantiva: la tasa de mal crédito se concentra alrededor del 30 %.

Hallazgo principal. La inferencia sobre la tasa de mal crédito es robusta frente a los tres priors considerados. Con $n = 1000$, los datos dominan la actualización y mantienen la media posterior próxima a 0.30.

11.6 Comparación con la inferencia frecuentista

En la Sección 8, el intervalo de Wilson fue:

$$\text{IC}_{95\%, \text{Wilson}} = [0.2724, 0.3291].$$

Con el prior uniforme, el intervalo creíble fue:

$$\text{ICr}_{95\%, \text{Beta}(1,1)} = [0.2724, 0.3291].$$

Los límites coinciden numéricamente al nivel de redondeo utilizado. Esta coincidencia no significa que ambos intervalos sean conceptualmente iguales.

El intervalo de Wilson se interpreta como una propiedad de un procedimiento repetido: en un conjunto hipotético de muestras comparables, aproximadamente el 95 % de los intervalos construidos mediante Wilson contendría el verdadero valor de p .

El intervalo creíble responde a una afirmación distinta:

$$\Pr(0.2724 \leq p \leq 0.3291 \mid x) = 0.95,$$

condicionada al modelo binomial, al prior uniforme y a los datos observados.

La similitud numérica se explica por el tamaño de la muestra y por el uso de un prior débil. En estas condiciones, tanto la aproximación frecuentista como la posterior se concentran cerca de la proporción muestral.

Cuadro 27: Comparación entre la inferencia frecuentista y bayesiana para la tasa de mal crédito.

Enfoque	Estimación	Intervalo del 95 %	Interpretación
Frecuentista: Wilson	$\hat{p} = 0.3000$	[0.2724, 0.3291]	Cobertura del procedimiento bajo muestreo repetido.
Bayesiano: Beta(1, 1)	MAP = 0.3000	[0.2724, 0.3291]	Probabilidad posterior condicionada al prior y los datos.

Ambos enfoques conducen a la misma conclusión aplicada: la tasa de mal crédito del conjunto analizado se estima cerca del 30 %, con una incertidumbre aproximada de tres puntos porcentuales a cada lado.

11.7 Supuestos y alcance del modelo

El modelo Beta–Binomial supone que, condicionado a p , los registros pueden representarse como ensayos Bernoulli comparables e independientes. También supone una única tasa común para toda la muestra.

Esta simplificación ignora posibles diferencias entre propósitos, duraciones, perfiles financieros o periodos de originación. El modelo describe la tasa agregada de la cartera, pero no sustituye la regresión logística utilizada para estimar probabilidades condicionales.

La posterior tampoco corrige problemas de representatividad de la muestra. Una distribución posterior estrecha puede reflejar alta precisión condicionada al dataset y, al mismo tiempo, coexistir con una validez externa limitada.

Por tanto, el intervalo creíble cuantifica la incertidumbre estadística sobre la tasa dentro del modelo asumido. No garantiza que la misma tasa sea aplicable a otra institución, país o periodo.

11.8 Regresión logística bayesiana

El modelo Beta–Binomial permitió obtener analíticamente la posterior de la tasa agregada de mal crédito. Sin embargo, la pregunta central del trabajo requiere estudiar probabilidades condicionales y determinar si la duración mantiene una asociación positiva después de controlar por las demás características.

Para este propósito se formuló una versión bayesiana de la regresión logística utilizada en la Sección 10. El coeficiente de interés es:

$$\beta_{\text{dur}},$$

asociado con la duración contractual del crédito.

La duración fue seleccionada porque presentó evidencia consistente en las distintas etapas del análisis:

- mostró la asociación monotónica marginal más alta con el mal crédito entre las variables numéricas;
- presentó una diferencia estadísticamente significativa entre buenos y malos créditos;
- conservó una asociación positiva dentro de la regresión logística multivariable;
- posee una interpretación directa en meses y puede relacionarse con políticas de plazo.

Aunque el objetivo final es estudiar la posterior marginal de β_{dur} , este coeficiente no se muestrea de manera aislada. La incertidumbre sobre la duración depende de sus relaciones con los demás predictores. Por ello, el sampler aproxima la posterior conjunta del vector completo:

$$\boldsymbol{\beta} \in \mathbb{R}^{24}.$$

Después del muestreo se extrae la componente correspondiente a la duración.

11.9 Especificación probabilística

Para cada observación del conjunto de entrenamiento:

$$Y_i \mid \boldsymbol{\beta} \sim \text{Bernoulli}(p_i),$$

con:

$$p_i = \sigma \left(\mathbf{x}_i^\top \boldsymbol{\beta} \right),$$

donde:

$$\sigma(\eta) = \frac{1}{1 + \exp(-\eta)}$$

es la función logística.

Se asignó a cada coeficiente un prior normal independiente:

$$\beta_j \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 10^2), \quad j = 1, \dots, 24.$$

La desviación estándar previa de 10 permite un rango amplio de valores en la escala logit. El prior reduce la probabilidad de coeficientes extremadamente grandes, pero deja que los 700 registros de entrenamiento determinen principalmente la posterior.

La log-verosimilitud Bernoulli-logit puede escribirse como:

$$\log L(\boldsymbol{\beta} \mid \mathbf{y}) = \sum_{i=1}^{700} [y_i \eta_i - \log(1 + \exp(\eta_i))],$$

donde:

$$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

El log-prior, omitiendo constantes que no dependen de los parámetros, es:

$$\log \pi(\boldsymbol{\beta}) = -\frac{1}{2(10)^2} \sum_{j=1}^{24} \beta_j^2.$$

Por tanto, la log-posterior no normalizada es:

$$\log \pi(\boldsymbol{\beta} \mid \mathbf{y}) = \sum_{i=1}^{700} [y_i \eta_i - \log(1 + \exp(\eta_i))] - \frac{\|\boldsymbol{\beta}\|^2}{2(10)^2}.$$

Los cálculos se implementaron en escala logarítmica para evitar problemas numéricos al multiplicar numerosas probabilidades pequeñas. En el código se utilizó `numpy.logaddexp()` para evaluar de forma estable el término:

$$\log(1 + \exp(\eta_i)).$$

11.10 Necesidad de simulación MCMC

La posterior de la regresión logística es:

$$\pi(\boldsymbol{\beta} \mid \mathbf{y}) = \frac{L(\mathbf{y} \mid \boldsymbol{\beta}) \pi(\boldsymbol{\beta})}{\int L(\mathbf{y} \mid \boldsymbol{\beta}) \pi(\boldsymbol{\beta}) d\boldsymbol{\beta}}.$$

La integral del denominador se desarrolla sobre un espacio de dimensión 24 y no dispone de una solución conjugada cerrada. Su evaluación directa no resulta práctica.

Metropolis–Hastings evita calcular esa constante de normalización. El algoritmo construye una cadena de Markov cuya distribución estacionaria es la posterior de interés. Después de alcanzar una región estable, los estados de la cadena permiten aproximar medias, cuantiles, probabilidades posteriores y transformaciones de los parámetros.

11.11 Sampler random-walk Metropolis–Hastings

El sampler fue implementado directamente en Python, sin utilizar una biblioteca especializada de MCMC.

11.11.1 Estado inicial

La cadena comienza en la estimación de máxima verosimilitud del modelo logístico frecuentista:

$$\beta^{(0)} = \hat{\beta}_{\text{MLE}}.$$

Este punto inicial se encuentra en una región de alta verosimilitud y, dado que el prior es débil, también en una región de elevada densidad posterior. Su utilización reduce la fase inicial de desplazamiento hacia la masa principal de la posterior.

Para el coeficiente de duración:

$$\hat{\beta}_{\text{dur,MLE}} = 0.03825,$$

con error estándar:

$$\text{EE}(\hat{\beta}_{\text{dur,MLE}}) = 0.01143.$$

11.11.2 Distribución de propuesta

En cada iteración se genera una propuesta multivariante:

$$\beta' = \beta^{(t)} + \frac{2.38}{\sqrt{d}} Lz,$$

donde:

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, I_d),$$

$$d = 24,$$

y:

$$LL^T = \widehat{\Sigma}_{MLE}.$$

La matriz L se obtuvo mediante la descomposición de Cholesky de la matriz de covarianza estimada del modelo frecuentista.

El factor de escala utilizado fue:

$$\frac{2.38}{\sqrt{24}} = 0.486.$$

Esta construcción adapta las propuestas a la escala y correlación de los coeficientes:

- genera desplazamientos menores en direcciones de alta concentración posterior;
- permite desplazamientos mayores en direcciones más dispersas;
- incorpora aproximadamente las correlaciones entre coeficientes.

La covarianza del MLE no se utiliza como estimación final de la posterior, sino como mecanismo para construir propuestas más eficientes.

11.11.3 Regla de aceptación

Debido a que la propuesta random-walk es simétrica, el cociente de Hastings correspondiente a la distribución de propuesta se cancela.

Se calcula:

$$\Delta = \log \pi(\boldsymbol{\beta}' | \mathbf{y}) - \log \pi(\boldsymbol{\beta}^{(t)} | \mathbf{y}).$$

La propuesta se acepta con probabilidad:

$$\alpha = \min[1, \exp(\Delta)].$$

En la implementación, la regla se evalúa mediante:

$$\log(U) < \Delta, \quad U \sim \text{Uniforme}(0, 1).$$

La comparación en escala logarítmica evita calcular explícitamente $\exp(\Delta)$ cuando la diferencia entre las densidades es muy grande.

Si la propuesta es aceptada:

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}'.$$

Si es rechazada:

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)}.$$

La repetición del estado actual es una parte necesaria del algoritmo y no un error de implementación.

11.12 Configuración de la simulación

La configuración utilizada se resume en la Tabla 29.

Cuadro 28: Configuración del sampler Metropolis–Hastings.

Elemento	Configuración
Observaciones de entrenamiento	700
Dimensión del vector	24 coeficientes
Estado inicial	Estimación de máxima verosimilitud
Prior	$\beta_j \sim \mathcal{N}(0, 10^2)$
Tipo de propuesta	Random-walk normal multivariante
Covarianza de la propuesta	Basada en $\hat{\Sigma}_{MLE}$
Escala	$2.38/\sqrt{24} = 0.486$
Iteraciones	40.000
Burn-in	8.000
Muestras retenidas	32.000
Semilla	SEED = 2026

Las primeras 8.000 iteraciones se descartaron como *burn-in*. Las 32.000 iteraciones restantes se utilizaron para aproximar la posterior marginal de β_{dur} .

No se aplicó *thinning*. Eliminar sistemáticamente iteraciones no reduce la autocorrelación de la cadena original y normalmente descarta información. En su lugar, la dependencia se cuantificó mediante el tamaño efectivo de muestra.

11.13 Diagnóstico de la cadena

La tasa de aceptación observada fue:

$$\hat{a} = 0.2568,$$

equivalente al:

$$25.68 \, \%.$$

Este valor se encuentra próximo a la referencia aproximada del 23 % para propuestas random-walk en problemas multivariantes. La cercanía no demuestra por sí sola una convergencia correcta, pero indica que la escala de la propuesta permitió un equilibrio razonable entre desplazamientos y aceptaciones.

El tamaño efectivo de muestra para el coeficiente de duración fue:

$$ESS(\beta_{dur}) \approx 429.$$

El ESS se estimó a partir de las autocorrelaciones de la cadena mediante una suma por pares consecutivos, interrumpida cuando el par se volvió negativo.

Aunque se retuvieron 32.000 valores, estos no equivalen a 32.000 observaciones independientes. La cadena random-walk presenta autocorrelación porque cada propuesta se construye a partir del estado anterior.

Un ESS cercano a 429 aporta información suficiente para estimar la media y los cuantiles principales de la posterior marginal, pero también evidencia que el sampler es menos eficiente que métodos como Hamiltonian Monte Carlo, MALA o propuestas adaptativas.

Figura 11. Metropolis-Hastings desde cero para el coeficiente de duración




Figura 11: Diagnóstico del sampler Metropolis–Hastings para el coeficiente de duración. El panel izquierdo muestra la traza completa y el final del burn-in. El panel derecho compara la posterior marginal simulada con la aproximación normal basada en el MLE.

La traza de la Figura 11 oscila alrededor de una región estable y no muestra una tendencia persistente. Tampoco se observa un cambio estructural después del burn-in. Este comportamiento es coherente con el uso del MLE como punto inicial.

La posterior marginal simulada presenta una forma aproximadamente unimodal y cercana a la aproximación normal frecuentista. La similitud gráfica es esperable con una muestra de entrenamiento de tamaño considerable y un prior débilmente informativo.

No obstante, el análisis utiliza una sola cadena. Por tanto, el gráfico de traza, la tasa de aceptación y el ESS ofrecen evidencia diagnóstica, pero no constituyen una demostración completa de convergencia. Una evaluación más rigurosa debería ejecutar varias cadenas con valores iniciales dispersos y calcular diagnósticos entre cadenas, como $\hat{R}$.

11.14 Posterior del coeficiente de duración

Después del burn-in, la media posterior fue:

$$E[\beta_{dur} | \mathbf{y}] = 0.04084.$$

La desviación estándar posterior fue:

$$SD [\beta_{\text{dur}} | \mathbf{y}] = 0.01121.$$

El intervalo creíble central del 95 % fue:

$$ICr_{95\%} (\beta_{\text{dur}}) = [0.01902, 0.06275].$$

Todo el intervalo se encuentra por encima de cero. Además, la proporción de muestras positivas fue:

$$\Pr (\beta_{\text{dur}} > 0 | \mathbf{y}) = 1.0000.$$

En la cadena retenida no se registró ninguna muestra no positiva. Este resultado proporciona evidencia posterior muy fuerte de una asociación positiva entre duración y mal riesgo, condicionada a los predictores incluidos, al prior y a la especificación logística.

El valor 1.0000 debe interpretarse como una estimación de Monte Carlo basada en las muestras generadas. No implica una certeza matemática absoluta fuera del modelo.

11.15 Interpretación mediante odds ratio

El odds ratio posterior correspondiente a un mes adicional se obtiene mediante:

$$OR_{\text{mes}} = \exp (\beta_{\text{dur}}) .$$

Al transformar la media posterior:

$$\exp(0.04084) = 1.0417.$$

El intervalo creíble del odds ratio es:

$$[\exp(0.01902), \exp(0.06275)] = [1.0192, 1.0648].$$

Manteniendo constantes las demás variables, cada mes adicional de duración se asocia con un aumento aproximado del:

$$100(1.0417 - 1) = 4.17 \%$$

en las *odds* de mal crédito.

Este cambio es multiplicativo. Para doce meses adicionales, el odds ratio posterior calculado a partir de la media es:

$$\exp (12 \times 0.04084) \approx 1.63.$$

Por tanto, un plazo superior en doce meses se asocia con unas *odds* aproximadamente 63 % mayores, manteniendo constantes las demás características.

Esta interpretación no equivale a un incremento de 63 puntos porcentuales en la probabilidad. El cambio absoluto de probabilidad depende del nivel inicial de riesgo de cada solicitante.

Hallazgo principal. La posterior del coeficiente de duración se concentra por completo en valores positivos. Cada mes adicional se asocia con un aumento posterior medio del 4.17 % en las *odds* de mal crédito, y la probabilidad posterior de un coeficiente positivo es aproximadamente uno.

11.16 Comparación con la estimación frecuentista

La Tabla 30 compara los dos enfoques.

Cuadro 29: Comparación frecuentista y bayesiana del coeficiente de duración.

Enfoque	Centro	Dispersión	Intervalo del 95 %	OR central
Máxima verosimilitud	0,038.25	EE = 0,011.43	[0.01585, 0.06065]	,039.0
Metropolis–Hastings	Media = 0,040.84	SD = 0,011.21	[0.01902, 0.06275]	,041.7

La media posterior es muy cercana al estimador de máxima verosimilitud:

$$0.04084 \approx 0.03825.$$

La desviación estándar posterior también se aproxima al error estándar frecuentista:

$$0.01121 \approx 0.01143.$$

Los intervalos presentan amplitudes similares y ambos excluyen el valor cero. Esta concordancia indica que la información de los datos domina el prior normal débil y que la aproximación asintótica del MLE describe de manera razonable la posterior marginal de este coeficiente.

La comparación constituye una verificación cruzada entre dos procedimientos, pero no convierte las interpretaciones en equivalentes. El intervalo frecuentista se refiere a la cobertura del procedimiento, mientras que el intervalo creíble expresa probabilidad posterior condicionada al prior y a los datos.

11.17 Evaluación crítica del sampler

El sampler implementado cumple el objetivo académico de construir desde cero un procedimiento Metropolis–Hastings multivariante y recuperar una posterior coherente con el modelo frecuentista.

Entre sus fortalezas se encuentran:

- la evaluación estable de la log-posterior;
- el uso de la covarianza del MLE para adaptar la forma de la propuesta;
- una tasa de aceptación razonable;
- la conservación explícita de los estados rechazados;
- el cálculo del burn-in, ESS e intervalo creíble.

Sus principales limitaciones son:

- se ejecutó una sola cadena;
- la propuesta no se adapta durante la simulación;
- el ESS es reducido respecto del número de iteraciones retenidas;
- los diagnósticos se concentran en β_{dur} y no en los 24 coeficientes;
- no se calculó $\widehat{R}$, porque este diagnóstico requiere varias cadenas.

Para una aplicación de investigación más extensa sería recomendable ejecutar varias cadenas con inicializaciones dispersas y emplear un sampler más eficiente, como Hamiltonian Monte Carlo. Sin embargo, para el objetivo de demostrar el procedimiento MCMC y analizar el coeficiente de duración, los resultados obtenidos son consistentes y reproducibles.

11.18 Conclusión del análisis bayesiano

El modelo Beta–Binomial mostró que la tasa global de mal crédito se estima cerca del 30 % y que la inferencia es estable frente a los priors uniforme, de Jeffreys e informativo débil.

La regresión logística bayesiana profundizó el análisis de la duración. La posterior del coeficiente se concentra en valores positivos, con:

$$E[\beta_{\text{dur}} | \mathbf{y}] = 0.04084,$$

$$\text{ICr}_{95\%} = [0.01902, 0.06275],$$

y:

$$\Pr(\beta_{\text{dur}} > 0 | \mathbf{y}) \approx 1.$$

Los resultados coinciden sustantivamente con la estimación por máxima verosimilitud y confirman que la duración es el factor numérico con la asociación condicional más consistente en el análisis.

Esta consistencia entre evidencia descriptiva, frecuentista, predictiva y bayesiana fortalece la interpretación, aunque continúa tratándose de una asociación observacional y no de un efecto causal.

12 Interpretación integrada

La pregunta central del trabajo fue:

¿Qué factores explican la probabilidad de que un solicitante sea clasificado como mal riesgo crediticio?

La evidencia obtenida muestra que el riesgo crediticio no se concentra en una única característica. La clasificación depende de una combinación entre las condiciones del préstamo, la liquidez disponible, los antecedentes financieros y algunos indicadores de estabilidad económica.

El término “explican” se utiliza en un sentido estadístico y predictivo. Los resultados permiten identificar variables asociadas con cambios en la probabilidad estimada de mal crédito, pero no demuestran que esas variables causen directamente el resultado observado.

12.1 Respuesta a la pregunta central

Dentro de las variables numéricas, la duración del préstamo constituye el factor con la asociación más consistente. Los créditos clasificados como malos presentan plazos mayores en el análisis descriptivo, una diferencia estandarizada cercana a moderada en la comparación frecuentista y un coeficiente positivo en la regresión logística.

En el modelo multivariable, cada mes adicional de duración se asocia con un incremento aproximado del 3.9 % en las *odds* de mal crédito, manteniendo constantes los demás predictores. El análisis bayesiano confirmó este resultado:

$$E[\beta_{\text{dur}} \mid \text{datos}] = 0.04084,$$

$$\text{ICr}_{95\%} = [0.01902, 0.06275],$$

y:

$$\Pr(\beta_{\text{dur}} > 0 \mid \text{datos}) \approx 1.$$

Por tanto, la duración es el principal factor numérico asociado con un mayor riesgo dentro de la especificación utilizada.

La carga de la cuota también mantiene una asociación condicional relevante. Una unidad adicional en la escala ordinal de `tasa_cuota` se relaciona con un aumento aproximado del 22.8 % en las *odds* de mal crédito:

$$OR = 1.2283.$$

Este resultado es coherente con la interpretación financiera de que una mayor proporción de recursos comprometida en el pago puede reducir el margen disponible frente a gastos inesperados. No obstante, la variable representa niveles ordinales y no porcentajes exactos del ingreso.

Entre las variables categóricas, el estado de la cuenta corriente, el nivel de ahorros, algunas categorías del historial crediticio, la antigüedad laboral y el tipo de vivienda aportan información adicional. En términos generales, los perfiles con mejores señales de liquidez o estabilidad presentan menores *odds* de mal crédito respecto de sus categorías de referencia.

La interpretación de estas categorías requiere cautela. Algunos códigos históricos combinan situaciones diferentes y ciertas asociaciones pueden parecer contraintuitivas debido a la categoría utilizada como referencia. En consecuencia, no deben convertirse directamente en reglas generales de aprobación o rechazo.

12.2 Diferencia entre asociación marginal y condicional

Uno de los resultados más importantes del análisis es la diferencia entre una asociación observada por separado y una asociación que permanece al controlar por otras variables.

El monto del crédito mostró inicialmente:

- valores medios y medianos superiores entre los malos créditos;
- una diferencia estadísticamente significativa mediante Mann–Whitney;
- una asociación positiva, aunque pequeña, con la clase de riesgo.

Sin embargo, dentro de la regresión logística:

$$OR_{\log(\text{monto})} = 1.0658,$$

con:

$$p = 0.7238.$$

El intervalo del 95 % contiene el valor uno. Por tanto, no existe evidencia suficiente de una asociación independiente del monto después de considerar duración, estado de cuenta, historial, ahorros, carga de la cuota y vivienda.

Este cambio es coherente con la relación observada entre monto y duración:

$$\rho_{\text{Spearman}} \approx 0.62.$$

Los créditos de mayor monto tienden a concederse por plazos más largos. En consecuencia, parte de la asociación marginal del monto con el riesgo parece estar capturada por la duración y por otras condiciones financieras.

La edad presenta un comportamiento parecido. Los malos créditos corresponden descriptivamente a solicitantes algo más jóvenes, pero la edad no conserva evidencia estadística dentro del modelo logístico:

$$OR_{\text{edad}} = 0.9972, \quad p = 0.7798.$$

Por tanto, ni el monto ni la edad deben considerarse factores condicionales principales en la especificación final.

12.3 Propósito del préstamo como factor de segmentación

La prueba chi-cuadrado identificó una asociación entre el propósito y la clase de riesgo:

$$\chi^2(9) = 33.356, \quad p = 0.00012.$$

La magnitud estimada mediante V de Cramér fue:

$$V = 0.183.$$

Esto indica una asociación global estadísticamente significativa, pero pequeña. Algunos propósitos presentan tasas observadas superiores al promedio, mientras que otros muestran tasas menores.

Sin embargo, el propósito debe entenderse principalmente como una variable de segmentación. Las tasas de algunas categorías se basan en pocos registros y pueden ser inestables. Además, la prueba global no controla por duración, monto, liquidez ni situación financiera.

Por ello, el propósito aporta contexto sobre el tipo de operación, pero no constituye por sí solo una base suficiente para determinar el riesgo individual de un solicitante.

12.4 Síntesis de la evidencia por factor

La Tabla 31 resume la relación entre los principales factores y el riesgo.

Cuadro 30: Síntesis integrada de los factores asociados con el riesgo crediticio.

Factor	Evidencia marginal	Evidencia condicional	Interpretación integrada
Duración	Los malos créditos tienen plazos mayores; $d = 0.480$.	OR = 1.0390 por mes; posterior completamente concentrada en valores positivos.	Factor numérico más consistente del análisis.
Tasa de la cuota	Mayor presencia de niveles altos entre los malos créditos.	OR = 1.2283, con intervalo por encima de uno.	Una mayor carga financiera se asocia con mayor riesgo.
Monto	Diferencia significativa entre clases; efecto pequeño.	OR = 1.0658, $p = 0.7238$.	Su asociación marginal no permanece después del control multivariable.
Estado de cuenta	Diferencias visibles entre perfiles de liquidez.	Varias categorías presentan OR < 1 frente al saldo negativo.	La liquidez corriente aporta una señal condicional importante.
Ahorros	Los perfiles con mayor ahorro muestran menor riesgo observado.	A64: OR = 0.1617 frente a menos de 100 DM.	Una mayor capacidad de ahorro se asocia con menor riesgo.
Historial crediticio	Las tasas cambian entre categorías.	Algunas categorías presentan asociaciones significativas respecto de A30.	Aporta información, pero depende fuertemente de la referencia y de la codificación histórica.
Vivienda	La distribución de las clases varía según el régimen de vivienda.	Vivienda propia: OR = 0.5868 frente al alquiler.	La estabilidad residencial se asocia con menores <i>odds</i> .
Propósito	Asociación global significativa, $V = 0.183$.	No se utilizó como predictor en la especificación logística final.	Útil para segmentación, con capacidad individual limitada.
Edad	Los malos créditos son ligeramente más jóvenes.	OR = 0.9972, $p = 0.7798$.	La diferencia marginal no persiste en el modelo conjunto.

12.5 Respuesta a las preguntas secundarias

Las preguntas específicas del trabajo pueden responderse de manera integrada.

12.5.1 ¿Cuál es la proporción global de malos créditos?

La proporción observada fue:

$$\hat{p} = 0.300.$$

El intervalo de Wilson del 95 % fue:

$$[0.2724, 0.3291],$$

mientras que el intervalo bootstrap fue:

$$[0.2720, 0.3290].$$

El modelo Beta–Binomial produjo intervalos creíbles prácticamente idénticos bajo los tres priors evaluados. La tasa se estima, por tanto, cerca del 30 %, con una incertidumbre aproximada de tres puntos porcentuales a cada lado.

12.5.2 ¿La tasa difiere según el propósito?

Sí. La prueba chi-cuadrado rechazó la hipótesis de independencia entre propósito y clase de riesgo. Sin embargo, la V de Cramér de 0.183 indica que la magnitud de la asociación es pequeña.

El propósito permite reconocer segmentos con tasas diferentes, pero no explica por sí solo la clasificación individual.

12.5.3 ¿La duración y el monto difieren entre las clases?

Ambas variables presentan diferencias marginales.

Los malos créditos tienen una duración media aproximadamente 5.65 meses mayor, con un tamaño de efecto:

$$d = 0.480.$$

El monto también tiende a ser mayor, pero su tamaño de efecto es pequeño:

$$r_{\text{rb}} = 0.110.$$

La diferencia esencial aparece en el análisis multivariable: la duración mantiene su asociación, mientras que el monto pierde significancia.

12.5.4 ¿Qué variables están asociadas con mayor riesgo?

La evidencia conjunta identifica como señales principales:

- mayor duración del crédito;
- mayor nivel de carga de la cuota;

- estado de cuenta menos favorable, especialmente la categoría de saldo negativo utilizada como referencia;
- menores niveles de ahorro;
- determinados perfiles del historial crediticio;
- menor estabilidad residencial frente a la vivienda propia.

La interpretación debe realizarse sobre el perfil completo. Ninguna variable ofrece una separación perfecta entre buenos y malos créditos.

12.5.5 ¿Cómo cambia la clasificación al modificar el umbral?

Con el umbral convencional:

$$t = 0.50,$$

el modelo obtiene una exactitud de 74.0 %, pero identifica solo el 46.7 % de los malos créditos.

Bajo la relación de costos 5 : 1, el umbral teórico es:

$$t^* = \frac{1}{6} \approx 0.1667.$$

Al aplicarlo, el recall aumenta a:

$$88.9 \%,$$

y los falsos negativos disminuyen de 48 a 10. A cambio, los falsos positivos aumentan y la exactitud disminuye al 60.7 %.

El costo total se reduce de:

$$270 \quad \text{a} \quad 158,$$

lo que representa una disminución aproximada del:

$$41.5 \%.$$

La modificación del umbral no mejora la capacidad discriminativa del modelo. Cambia la política de decisión y el equilibrio entre los dos tipos de error.

12.6 Coherencia entre los enfoques estadísticos

Los resultados frecuentistas y bayesianos presentan una alta consistencia.

Para la tasa global de mal crédito:

$$\hat{p}_{\text{frecuentista}} = 0.3000,$$

mientras que, con el prior uniforme:

$$\hat{p}_{\text{MAP}} = 0.3000.$$

El intervalo de Wilson y el intervalo creíble bajo Beta(1, 1) coinciden numéricamente al nivel de redondeo:

$$[0.2724, 0.3291].$$

Para la duración, el estimador frecuentista fue:

$$\hat{\beta}_{\text{dur,MLE}} = 0.03825,$$

y la media posterior:

$$E[\beta_{\text{dur}} | \text{datos}] = 0.04084.$$

Las diferencias son pequeñas. Esta concordancia es esperable debido al tamaño de la muestra y al uso de distribuciones previas débiles.

La similitud numérica no elimina la diferencia conceptual. La inferencia frecuentista describe propiedades del procedimiento de estimación bajo muestreo repetido. La inferencia bayesiana expresa incertidumbre posterior condicionada al prior y a los datos observados.

12.7 Predicción y utilidad operativa

La regresión logística alcanzó:

$$\text{AUC}_{\text{test}} = 0.7740,$$

y una media de validación cruzada de:

$$\overline{\text{AUC}_{\text{CV}}} = 0.7685 \pm 0.0221.$$

La proximidad entre ambos resultados indica una capacidad discriminativa estable dentro del esquema de evaluación utilizado.

Sin embargo, una AUC cercana a 0.77 no implica una clasificación perfecta ni determina automáticamente una política crediticia adecuada. El modelo ordena razonablemente los perfiles, pero existe un solapamiento considerable entre las clases.

La utilidad operativa depende de tres niveles diferentes:

1. **Estimación del riesgo:** producción de una probabilidad individual de mal crédito;

2. **Discriminación:** capacidad de ordenar correctamente casos de mayor y menor riesgo;
3. **Decisión:** elección de un umbral compatible con los costos y objetivos de la institución.

Un modelo puede mostrar una discriminación estable y, al mismo tiempo, producir decisiones costosas cuando se utiliza un umbral inadecuado.

12.8 Implicancias para una política crediticia

Los resultados sugieren que las operaciones de larga duración y elevada carga de cuota requieren una revisión más cuidadosa. Esto no implica que deban rechazarse automáticamente. Una política de gestión podría considerar:

- reducir el plazo cuando la capacidad de pago sea limitada;
- solicitar garantías adicionales en operaciones de mayor riesgo;
- ajustar el monto o la estructura de cuotas;
- establecer una revisión manual para probabilidades cercanas al umbral;
- incorporar información financiera más reciente antes de la decisión final.

El monto no debería utilizarse aisladamente como argumento de riesgo. Su asociación marginal desaparece después de considerar la duración y otras características.

Del mismo modo, categorías personales o históricas no deben convertirse automáticamente en reglas de exclusión. Su utilización debe someterse a criterios de pertinencia, equidad y regulación.

12.9 Respuesta integrada final

La probabilidad de mal riesgo crediticio se asocia principalmente con la combinación de plazos prolongados, mayor carga de la cuota y señales menos favorables de liquidez o estabilidad financiera.

La duración es el factor numérico más consistente: aparece en el análisis exploratorio, la comparación frecuentista, la regresión logística y la posterior bayesiana. El estado de cuenta, los ahorros, el historial crediticio y la vivienda complementan esta señal.

El monto y la edad muestran diferencias marginales, pero no conservan evidencia condicional dentro del modelo final. El propósito está asociado globalmente con el riesgo, aunque su magnitud es pequeña y su utilidad principal es la segmentación.

Finalmente, el desempeño del sistema no depende únicamente de la calidad del modelo. La selección del umbral modifica sustancialmente los errores y los costos. Bajo la matriz 5 : 1, el umbral 1/6 resulta más coherente que 0.50, porque prioriza la detección de malos créditos y reduce el costo total observado.

En consecuencia, el modelo debe entenderse como una herramienta de apoyo a la decisión: combina información sobre el perfil y la operación, produce una estimación de riesgo y permite adaptar la clasificación a los costos del problema. No constituye una explicación

causal ni un sistema listo para despliegue sin validación externa, recalibración y revisión de equidad.

13 Limitaciones y validez

Los resultados obtenidos son consistentes dentro del conjunto de datos y de los procedimientos aplicados, pero su interpretación está condicionada por la calidad de la fuente, la definición de la respuesta, los supuestos estadísticos y el diseño de evaluación.

Esta sección distingue cinco dimensiones: validez interna, validez de constructo, validez predictiva, validez externa y validez operativa. También se consideran las limitaciones específicas del análisis bayesiano y los riesgos asociados con el uso de variables sensibles.

13.1 Validez interna

La validez interna se refiere a la coherencia entre los datos, los métodos aplicados y las conclusiones obtenidas dentro del estudio.

El flujo de análisis presenta varias fortalezas:

- la variable respuesta fue recodificada de manera explícita como 1 = mal crédito;
- no se detectaron valores faltantes ni filas completamente duplicadas;
- las dimensiones, categorías y rangos fueron verificados antes del análisis;
- las comparaciones inferenciales se acompañaron con tamaños de efecto;
- la regresión OLS fue evaluada mediante diagnósticos gráficos, pruebas formales y validación cruzada;
- la regresión logística fue evaluada fuera de muestra y mediante validación cruzada estratificada;
- los resultados frecuentistas se contrastaron con estimaciones bayesianas.

Sin embargo, el estudio continúa siendo observacional. Las asociaciones identificadas no se obtuvieron mediante una asignación aleatoria de duraciones, montos o condiciones financieras. Por ello, no es posible atribuir un efecto causal a los predictores.

Por ejemplo, el coeficiente positivo de la duración puede reflejar una combinación de factores:

- exposición durante un horizonte más prolongado;
- necesidad de financiar montos mayores;
- menor capacidad de pago mensual;
- reglas de originación no observadas;
- características del solicitante que no aparecen en el dataset.

La regresión reduce parcialmente la confusión al controlar por varias variables, pero no elimina el sesgo derivado de factores omitidos.

13.2 Validez de constructo

La validez de constructo examina si las variables disponibles representan adecuadamente los conceptos que se pretende estudiar.

13.2.1 Definición de mal riesgo

La respuesta original clasifica cada registro como buen o mal riesgo, pero la documentación disponible no especifica completamente:

- el horizonte durante el cual se evaluó el comportamiento;
- el número de días de atraso considerado como incumplimiento;
- si la etiqueta incorpora refinanciaciones, pérdidas o recuperación;
- si la clasificación fue asignada mediante una regla automática, evaluación humana o combinación de ambas.

Por tanto, `mal_credito` debe interpretarse como la etiqueta de riesgo proporcionada por la fuente, no como una definición contemporánea y universal de *default*.

Esta diferencia es importante porque una institución podría utilizar una definición distinta, por ejemplo, mora superior a noventa días dentro de los doce meses posteriores a la originación. Un cambio en esa definición modificaría la prevalencia, los coeficientes y las métricas del modelo.

13.2.2 Variables ordinales

Las variables `tasa_cuota` y `anios_residencia` están codificadas mediante valores enteros entre 1 y 4. Estos valores representan niveles ordenados, pero no se conocen las distancias exactas entre las categorías.

Al utilizarlas como términos lineales se supone implícitamente que el cambio entre los niveles 1 y 2 es comparable con el cambio entre los niveles 3 y 4. Esta simplificación mejora la parsimonia, pero puede no representar correctamente la relación real.

Una alternativa sería incorporarlas mediante indicadores categóricos o comparar modelos con funciones no lineales.

13.2.3 Categorías ambiguas

Algunos códigos combinan situaciones conceptualmente diferentes. Por ejemplo:

- A65 representa ahorros desconocidos o ausencia de una cuenta de ahorros;
- A124 representa propiedad desconocida o inexistente;

- `estatus_personal_sexo` combina sexo y estado personal en una sola variable.

Estas categorías impiden distinguir si una asociación se debe a ausencia real del recurso, falta de información o una combinación de ambas situaciones.

Por esta razón, los coeficientes correspondientes no deben interpretarse como efectos precisos de una única condición.

13.3 Sesgo de selección

El dataset contiene únicamente registros para los cuales existe una clasificación final de riesgo. No se dispone de información sobre las personas que solicitaron un crédito y fueron rechazadas antes de ingresar a la cartera observada.

Esta situación puede generar sesgo de selección. El modelo aprende a distinguir buenos y malos resultados dentro de la población aceptada o evaluada por el proceso original, pero no necesariamente dentro de toda la población solicitante.

En riesgo crediticio, este problema se relaciona con el *reject inference*. Los perfiles rechazados podrían presentar distribuciones diferentes de ingresos, liquidez, historial o duración. Al no observar sus resultados potenciales, no es posible estimar directamente cómo se habría comportado el modelo sobre ellos.

En consecuencia:

$$\Pr(Y = 1 \mid X, \text{registro observado})$$

no necesariamente coincide con:

$$\Pr(Y = 1 \mid X, \text{población total de solicitantes}) .$$

Esta limitación afecta tanto la interpretación de los coeficientes como una eventual política de aprobación.

13.4 Validez predictiva

La regresión logística alcanzó una AUC de prueba de:

$$0.7740,$$

y una AUC media de validación cruzada de:

$$0.7685 \pm 0.0221.$$

La cercanía entre ambos resultados sugiere estabilidad dentro de las particiones evaluadas. Sin embargo, esta evidencia no constituye una validación completa.

13.4.1 Partición aleatoria

El conjunto de prueba fue obtenido mediante una partición aleatoria estratificada. Este diseño evalúa el desempeño cuando entrenamiento y prueba proceden de una distribución similar.

No se realizó una validación temporal, porque el dataset no proporciona una variable de fecha adecuada. En una cartera real, las condiciones macroeconómicas, las políticas de aprobación y el comportamiento de los clientes cambian con el tiempo.

Por tanto, el desempeño obtenido no permite evaluar:

- degradación temporal del modelo;
- cambios en la población solicitante;
- modificaciones de la política crediticia;
- efectos de inflación, desempleo o tasas de interés;
- estabilidad de las categorías a través del tiempo.

13.4.2 Tamaño del conjunto de prueba

El conjunto de prueba contiene 300 observaciones, de las cuales 90 corresponden a mal riesgo. Las métricas dependen de un número relativamente limitado de casos positivos.

Por ejemplo, una variación de nueve malos créditos correctamente clasificados modifica el recall en diez puntos porcentuales. Esto implica que las métricas operativas pueden presentar variabilidad relevante entre muestras.

La validación cruzada reduce la dependencia de una única partición, pero no sustituye una validación externa sobre una cartera independiente.

13.4.3 Calibración

La AUC mide capacidad de ordenamiento, no calibración. Un modelo puede asignar puntajes mayores a los malos créditos y, al mismo tiempo, sobreestimar o subestimar sus probabilidades absolutas.

El umbral teórico:

$$t^* = \frac{1}{6}$$

se deriva de la matriz de costos suponiendo probabilidades razonablemente calibradas. El trabajo no incluyó formalmente:

- curva de calibración;
- puntuación de Brier;
- intercepto y pendiente de calibración;

- recalibración mediante Platt o regresión isotónica.

Por ello, la reducción de costo observada demuestra la utilidad del umbral dentro del conjunto evaluado, pero no garantiza que el mismo punto de corte sea óptimo en una cartera futura.

13.5 Especificación del modelo

La regresión logística supone que los predictores numéricos mantienen una relación lineal con el logit de la probabilidad:

$$\log \left(\frac{p}{1-p} \right).$$

Esta condición no fue evaluada mediante splines, polinomios o pruebas específicas de linealidad para cada predictor. Es posible que la relación entre duración y riesgo cambie en distintos rangos; por ejemplo, que el aumento de riesgo entre 12 y 24 meses no sea equivalente al observado entre 48 y 60 meses.

Tampoco se incorporaron interacciones. Una misma duración podría tener implicaciones diferentes según:

- el nivel de ahorros;
- la carga de la cuota;
- el estado de la cuenta;
- el propósito del préstamo.

El modelo fue mantenido deliberadamente interpretable y parsimonioso. Esta decisión facilita la lectura de los coeficientes, pero puede limitar la capacidad para capturar patrones complejos.

13.6 Variables omitidas

La base no contiene varias características que serían relevantes en un modelo crediticio contemporáneo, entre ellas:

- ingreso mensual exacto;
- relación cuota-ingreso calculada;
- nivel total de endeudamiento;
- comportamiento reciente de pagos;
- consultas anteriores en centrales de riesgo;
- estabilidad y sector del ingreso;
- garantías y relación préstamo-valor;

- información macroeconómica;
- fecha de originación y fecha de observación.

La omisión de estos predictores limita tanto la discriminación como la interpretación de las variables disponibles. Parte del efecto atribuido a duración, ahorros o vivienda puede representar indirectamente información financiera no observada.

13.7 Categorías poco frecuentes

Algunas categorías contienen un número reducido de registros. Esto se observó especialmente en determinados propósitos y niveles categóricos.

Los grupos pequeños generan:

- tasas observadas inestables;
- intervalos de confianza amplios;
- coeficientes logísticos con mayor error estándar;
- sensibilidad frente a pocas observaciones.

Aunque la prueba chi-cuadrado cumplió los criterios habituales de frecuencias esperadas, los porcentajes de categorías pequeñas deben interpretarse como evidencia exploratoria y no como reglas estables de segmentación.

En una aplicación real sería necesario evaluar si corresponde agrupar categorías sobre una base estadística y de negocio, evitando combinaciones arbitrarias realizadas únicamente para mejorar el ajuste.

13.8 Multiplicidad e interpretación de significancia

El modelo logístico incluye varios coeficientes categóricos y se examinaron múltiples asociaciones. Cada valor p fue interpretado con un nivel nominal de 0.05, sin aplicar una corrección formal por comparaciones múltiples.

Esto incrementa la posibilidad de identificar alguna asociación estadísticamente significativa por azar. Por ejemplo, el resultado de la antigüedad laboral entre cuatro y siete años presenta:

$$p = 0.0497,$$

con un intervalo cuyo límite superior se encuentra muy próximo a uno. Esta asociación debe considerarse débil y requiere confirmación externa.

Las conclusiones principales no se apoyan exclusivamente en ese tipo de resultados limítrofes. Se priorizó la consistencia entre análisis descriptivo, inferencia, regresión, validación y análisis bayesiano.

13.9 Validez externa

El dataset fue publicado en 1994 y corresponde a un contexto financiero alemán. Las características económicas, regulatorias y tecnológicas del mercado crediticio han cambiado de manera sustancial desde entonces.

Entre las diferencias relevantes se encuentran:

- sistemas actuales de centrales de riesgo;
- procesos digitales de originación;
- nuevas fuentes de información transaccional;
- cambios regulatorios sobre protección al consumidor;
- variaciones en empleo, ingresos, inflación y tasas;
- evolución de las políticas de inclusión financiera.

Además, el monto se expresa en marcos alemanes y las categorías reflejan productos y prácticas de la época. No es válido trasladar directamente los coeficientes, tasas o umbrales a una institución peruana contemporánea.

Una aplicación en otro contexto requeriría:

1. definir nuevamente el evento de incumplimiento;
2. construir una muestra reciente y representativa;
3. recalibrar las probabilidades;
4. estimar costos institucionales reales;
5. validar el modelo temporal y externamente;
6. revisar las variables permitidas por la regulación local.

Por tanto, el trabajo demuestra un procedimiento de análisis, no un modelo transferible sin ajustes.

13.10 Validez operativa y matriz de costos

La matriz de costos asigna un costo de cinco unidades a un falso negativo y una unidad a un falso positivo. Esta relación permitió comparar políticas de decisión, pero constituye una simplificación.

En una institución real, el costo de un falso negativo no es constante. Depende, entre otros factores, de:

- monto expuesto al incumplimiento;
- probabilidad de incumplimiento;
- pérdida dado incumplimiento;

- exposición al momento del incumplimiento;
- recuperaciones y garantías;
- gastos legales y de cobranza.

El costo de un falso positivo tampoco se limita a una unidad fija. Puede incluir margen financiero perdido, costo de adquisición del cliente, valor de relaciones futuras y consecuencias de exclusión financiera.

Por ello, el umbral 1/6 debe interpretarse como la solución teórica del ejercicio bajo costos constantes 5 : 1, no como una política crediticia universal.

13.11 Equidad y variables sensibles

El dataset contiene variables que pueden ser sensibles o actuar como proxies de características protegidas:

- edad;
- sexo y estado personal combinados;
- condición de trabajador extranjero;
- vivienda;
- situación laboral.

El estudio no realizó una auditoría formal de equidad. No se calcularon métricas como:

- paridad de selección;
- igualdad de oportunidades;
- igualdad de tasas de falsos positivos;
- calibración por subgrupo;
- impacto adverso.

En consecuencia, un desempeño global aceptable no garantiza que los errores se distribuyan de manera equitativa entre grupos.

Además, algunas variables aparentemente financieras pueden funcionar como proxies de condiciones sociales o demográficas. Eliminar una variable sensible tampoco garantiza automáticamente equidad, porque otras variables correlacionadas pueden conservar parte de la misma información.

Una aplicación responsable requeriría evaluar el desempeño por subgrupo, revisar la legitimidad de cada predictor y mantener mecanismos de explicación y apelación.

13.12 Riesgo de automatización

El modelo produce una probabilidad estimada y una clasificación derivada de un umbral. Sin embargo, estas salidas no deben interpretarse como una decisión definitiva.

Una automatización sin supervisión podría:

- amplificar patrones históricos;
- rechazar perfiles solventes;
- ocultar errores detrás de una probabilidad aparentemente objetiva;
- dificultar la revisión de casos excepcionales;
- generar dependencia excesiva del modelo.

El uso apropiado sería como herramienta de apoyo. Los casos cercanos al umbral, con información incompleta o con consecuencias especialmente altas deberían pasar por revisión adicional.

También sería necesario registrar las razones de decisión, monitorear la deriva del modelo y permitir correcciones cuando se detecten errores.

13.13 Limitaciones del análisis OLS

La regresión OLS tuvo como respuesta el logaritmo del monto y no la clase de riesgo. Su finalidad fue describir la estructura del monto y evaluar los supuestos de un modelo lineal múltiple.

Aunque la transformación redujo la asimetría, la prueba de Shapiro–Wilk rechazó la normalidad estricta de los residuos:

$$p = 0.00275.$$

La muestra grande hace que la prueba sea sensible a desviaciones pequeñas, y la inferencia robusta HC3 mantuvo las conclusiones. No obstante, el modelo no debe interpretarse como una representación perfecta del proceso de determinación del monto.

Tampoco se incorporaron variables categóricas, interacciones ni relaciones no lineales en esa especificación auxiliar. El R^2 cercano a 0.54 indica una capacidad explicativa relevante, pero deja una parte importante de variabilidad sin explicar.

13.14 Limitaciones del análisis bayesiano

El modelo Beta–Binomial supone una única tasa común de mal crédito y no representa la heterogeneidad entre perfiles. Su posterior estrecha refleja la precisión de la tasa agregada dentro del modelo, pero no elimina los problemas de selección o representatividad.

La sensibilidad al prior fue reducida porque la muestra contiene 1000 registros y los priors utilizados son débiles. Esta robustez no garantiza que toda elección previa produzca el mismo

resultado. Un prior muy concentrado o una muestra pequeña podría modificar sustancialmente la posterior.

El análisis Metropolis–Hastings presenta limitaciones adicionales:

- se ejecutó una sola cadena;
- no fue posible calcular $\hat{R}$;
- el ESS del coeficiente de duración fue aproximadamente 429, pese a retener 32.000 iteraciones;
- los diagnósticos se concentraron principalmente en el coeficiente de duración;
- no se evaluó la sensibilidad a otras escalas del prior;
- no se comparó el sampler con métodos MCMC más eficientes.

La tasa de aceptación de 25.68 %, la traza estable y la coherencia con el MLE respaldan el resultado, pero no constituyen una demostración completa de convergencia de la posterior conjunta.

Para un análisis bayesiano más riguroso sería necesario ejecutar varias cadenas, utilizar inicializaciones dispersas y evaluar todos los coeficientes mediante ESS, $\hat{R}$, trazas y autocorrelaciones.

13.15 Reproducibilidad y dependencia computacional

El notebook fija una semilla, registra versiones de las principales bibliotecas, descarga el dataset cuando no está disponible y exporta las figuras y tablas utilizadas en el informe.

No obstante, la reproducción exacta puede depender de:

- versiones de Python y de las bibliotecas;
- cambios futuros en la ubicación del archivo de UCI;
- diferencias numéricas entre plataformas;
- actualizaciones de los algoritmos internos de optimización;
- modificaciones accidentales del notebook después de generar los resultados.

Para reducir estos riesgos, el repositorio debe conservar:

- el archivo de dependencias;
- la semilla global;
- los artefactos exportados;
- el historial de Git;
- instrucciones de ejecución desde un entorno limpio.

La consistencia entre notebook, tablas, figuras e informe debe comprobarse antes de la entrega final.

13.16 Resumen de limitaciones

La Tabla 32 sintetiza los principales riesgos de validez.

Cuadro 31: Principales limitaciones y sus consecuencias.

Dimensión	Limitación	Consecuencia
Interna	Datos observacionales y posibles variables omitidas.	Las asociaciones no permiten establecer causalidad.
Constructo	Definición incompleta de la clase de mal riesgo.	La respuesta puede no coincidir con una definición actual de incumplimiento.
Selección	Ausencia de solicitantes rechazados.	El modelo describe la población observada, no necesariamente a todos los solicitantes.
Predictiva	Partición aleatoria sin validación temporal ni externa.	La estabilidad futura del desempeño no está demostrada.
Calibración	No se evaluó formalmente la calibración.	El umbral de costos depende de probabilidades cuya precisión absoluta no fue validada.
Externa	Datos alemanes históricos.	Los coeficientes y umbrales no pueden trasladarse directamente a una cartera peruana contemporánea.
Operativa	Matriz de costos fija 5 : 1.	El umbral obtenido es académico y no sustituye una estimación económica institucional.
Equidad	Presencia de variables sensibles y ausencia de auditoría por subgrupos.	No puede asegurarse una distribución equitativa de los errores.
Bayesiana	Una sola cadena y ESS limitado.	Los resultados MCMC requieren diagnósticos adicionales para una validación completa.

13.17 Alcance válido de las conclusiones

Considerando las limitaciones anteriores, las conclusiones son válidas dentro del siguiente alcance:

Los resultados describen asociaciones y capacidad predictiva dentro del conjunto *Statlog German Credit Data*, bajo la codificación, los predictores, los modelos y los costos especificados en el trabajo.

No resulta válido afirmar que:

- una mayor duración cause necesariamente incumplimiento;
- los coeficientes estimados se mantengan en cualquier país o periodo;

- el umbral 1/6 sea óptimo para toda institución;
- el modelo pueda aprobar o rechazar créditos sin revisión;
- la ausencia de una auditoría de equidad implique ausencia de sesgo.

La principal contribución del estudio es metodológica: muestra cómo integrar análisis exploratorio, inferencia frecuentista, regresión, validación predictiva, costos asimétricos e inferencia bayesiana dentro de un flujo reproducible.

Los resultados constituyen una base para formular hipótesis y diseñar una validación más completa, no una política crediticia lista para despliegue.

14 Conclusiones

El trabajo integró análisis exploratorio, inferencia frecuentista, regresión, evaluación predictiva, costos asimétricos e inferencia bayesiana para estudiar los factores asociados con la clasificación de mal riesgo crediticio en el conjunto *Statlog German Credit Data*.

La pregunta central fue determinar qué factores explican, en un sentido estadístico y predictivo, la probabilidad de que un solicitante sea clasificado como mal riesgo. Los resultados permiten formular las siguientes conclusiones.

14.1 Conclusiones principales

1. La tasa global de mal crédito se estima con precisión alrededor del 30 %.

De las 1000 observaciones, 300 corresponden a mal riesgo. El intervalo de Wilson del 95 % fue:

$$[0.2724, 0.3291],$$

mientras que el intervalo bootstrap percentil fue:

$$[0.2720, 0.3290].$$

La cercanía entre ambos procedimientos muestra que la estimación de la tasa es estable frente a los métodos frecuentistas utilizados.

El modelo Beta–Binomial produjo resultados prácticamente coincidentes. Bajo el prior uniforme, la estimación MAP fue 0.3000 y el intervalo creíble del 95 % fue $[0.2724, 0.3291]$. La sensibilidad frente a los priors uniforme, de Jeffreys e informativo débil fue mínima.

2. El propósito del préstamo está asociado con la clase de riesgo, aunque la magnitud de la relación es pequeña.

La prueba de independencia produjo:

$$\chi^2(9) = 33.356, \quad p = 0.00012.$$

Sin embargo, la V de Cramér fue:

$$V = 0.183.$$

Por tanto, el propósito aporta información para segmentar la cartera, pero no constituye una variable suficiente para clasificar individualmente a un solicitante. Las tasas extremas de las categorías con pocos registros deben interpretarse con especial cautela.

3. La duración es el factor numérico más consistente asociado con el mal riesgo.

Los créditos de mal riesgo presentan una duración media aproximadamente 5.65 meses mayor que los buenos créditos. La prueba de Welch confirmó la diferencia y la d de Cohen fue:

$$d = 0.480.$$

En la regresión logística, cada mes adicional se asoció con un aumento aproximado del 3.9 % en las *odds* de mal crédito:

$$OR = 1.0390, \quad p = 0.0008.$$

El análisis mediante Metropolis–Hastings confirmó esta asociación. La media posterior del coeficiente fue:

$$E[\beta_{\text{dur}} \mid \text{datos}] = 0.04084,$$

con intervalo creíble:

$$[0.01902, 0.06275],$$

y:

$$\Pr(\beta_{\text{dur}} > 0 \mid \text{datos}) \approx 1.$$

La consistencia entre la evidencia descriptiva, frecuentista, multivariable y bayesiana convierte a la duración en el resultado numérico más sólido del estudio.

4. El monto presenta una asociación marginal con el riesgo, pero no conserva evidencia condicional.

Los malos créditos presentan montos generalmente mayores. La prueba de Mann–Whitney detectó una diferencia estadísticamente significativa:

$$U = 116\,520, \quad p = 0.00592.$$

No obstante, el tamaño de efecto fue pequeño:

$$r_{rb} = 0.110.$$

En el modelo logístico multivariable:

$$OR_{\log(\text{monto})} = 1.0658, \quad p = 0.7238.$$

Por tanto, el monto no aporta evidencia de una asociación independiente después de controlar por duración, liquidez, historial, ahorros, vivienda y carga de la cuota. Parte de su señal marginal está compartida con la duración, cuya correlación de Spearman con el monto fue aproximadamente 0.62.

5. Las condiciones de liquidez y estabilidad financiera complementan la información aportada por la duración.

El estado de la cuenta corriente, el nivel de ahorros, determinadas categorías del historial crediticio, la vivienda y la carga de la cuota conservaron asociaciones relevantes dentro del modelo logístico.

En particular, una unidad adicional en la escala de carga de la cuota se asoció con un aumento aproximado del 22.8 % en las *odds* de mal crédito:

$$OR = 1.2283.$$

Los niveles elevados de ahorro y la vivienda propia mostraron menores *odds* respecto de sus categorías de referencia. Estas relaciones sugieren que la evaluación del riesgo debe considerar el perfil financiero completo y no una característica aislada.

6. El modelo logístico muestra una capacidad discriminativa estable, aunque no perfecta.

La regresión logística alcanzó:

$$AUC_{\text{test}} = 0.7740,$$

mientras que la validación cruzada estratificada produjo:

$$\overline{AUC}_{CV} = 0.7685 \pm 0.0221.$$

La proximidad entre ambos resultados indica estabilidad entre particiones y ausencia de una brecha importante de sobreajuste bajo el diseño aplicado.

Sin embargo, una AUC cercana a 0.77 implica que todavía existe un solapamiento relevante entre buenos y malos créditos. El modelo mejora el ordenamiento del riesgo, pero no permite una separación completa de las clases.

7. La elección del umbral modifica de manera sustancial la utilidad operativa del modelo.

Con el umbral convencional de 0.50, el modelo obtiene una exactitud del 74.0 %, pero identifica únicamente el 46.7 % de los malos créditos. La matriz de confusión contiene 48 falsos negativos.

Bajo la matriz de costos 5 : 1, el umbral teórico es:

$$t^* = \frac{1}{6} \approx 0.1667.$$

Con este punto de corte, el recall aumenta al 88.9 % y los falsos negativos disminuyen de 48 a 10. Como contrapartida, aumentan los falsos positivos y la exactitud disminuye al 60.7 %.

El costo total observado se reduce de:

$$270 \quad \text{a} \quad 158,$$

equivalente a una reducción aproximada del:

$$41.5 \, \%.$$

Este resultado demuestra que la exactitud no debe ser el único criterio para evaluar un modelo de riesgo. La política de decisión debe relacionarse explícitamente con el costo desigual de los errores.

15 Declaración de contribución individual

El trabajo fue desarrollado de manera colaborativa por los tres integrantes del Grupo 5. Para organizar las responsabilidades, el análisis se dividió en tres bloques temáticos coherentes: preparación y exploración de los datos; inferencia frecuentista y regresión lineal; y modelamiento predictivo e inferencia bayesiana.

La distribución porcentual representa la responsabilidad principal asumida por cada integrante sobre el desarrollo, validación y documentación de su bloque. Esta asignación no excluye la revisión cruzada ni la participación conjunta en la interpretación de los resultados.

La contribución total declarada es:

$$40 \, \% + 30 \, \% + 30 \, \% = 100 \, \%.$$

La Tabla 33 resume la distribución general de responsabilidades.

Cuadro 32: Distribución de las contribuciones individuales.

Integrante	Bloque y participación	Responsabilidades principales
Henry Sánchez Alvarado	Bloque 1 Preparación, exploración e incertidumbre 40 %	Organización general del flujo reproducible; documentación y carga del dataset; elaboración del diccionario de variables; validación, limpieza y recodificación de la respuesta; análisis exploratorio y estadística descriptiva; ajuste paramétrico del monto; desarrollo de las visualizaciones iniciales; estimación de intervalos de confianza mediante Wilson, bootstrap y distribución t ; integración de la estructura general del informe y revisión de la correspondencia entre notebook, resultados e informe.
Armando Castro Chaupis	Bloque 2 Inferencia frecuentista y regresión lineal 30 %	Formulación y evaluación de las hipótesis frecuentistas; aplicación de la prueba chi-cuadrado y cálculo de la V de Cramér; comparación de la duración mediante la prueba de Welch y la d de Cohen; comparación del monto mediante Mann–Whitney y tamaños de efecto; especificación e interpretación del modelo OLS; evaluación de multicolinealidad, normalidad, homocedasticidad e influencia; comparación con errores robustos HC3 y validación cruzada del modelo lineal.
Alex Segura Núñez	Bloque 3 Predicción, costos e inferencia bayesiana 30 %	Especificación y ajuste de la regresión logística; preparación de la partición estratificada de entrenamiento y prueba; interpretación de coeficientes y odds ratios; evaluación mediante ROC–AUC, KS, precisión, recall, especificidad, F1 y matrices de confusión; validación cruzada del clasificador; comparación de los umbrales 0.50 y 1/6 bajo la matriz de costos 5 : 1; desarrollo del modelo Beta–Binomial; análisis de sensibilidad al prior; implementación y diagnóstico de Metropolis–Hastings; integración de los resultados predictivos y bayesianos.

15.1 Responsabilidades compartidas

Aunque cada integrante asumió la responsabilidad principal de un bloque, el trabajo no se desarrolló de manera aislada. Los tres miembros participaron conjuntamente en:

- definición y revisión de la pregunta de investigación;
- discusión de los supuestos estadísticos y del alcance del análisis;
- interpretación de los resultados desde la perspectiva del riesgo crediticio;
- revisión de la coherencia entre el notebook, las tablas CSV, las figuras y el informe;

- revisión crítica de las conclusiones, limitaciones y recomendaciones;
- preparación de la exposición y validación de la versión final del proyecto.

15.2 Responsabilidad académica

Cada integrante revisó el bloque bajo su responsabilidad y confirmó que comprende:

- la procedencia, estructura y codificación de los datos;
- las transformaciones y variables derivadas utilizadas;
- los métodos estadísticos y computacionales implementados;
- la interpretación de los coeficientes, intervalos y métricas;
- los supuestos y limitaciones de las pruebas y modelos;
- la diferencia entre asociación estadística, predicción y causalidad.

La responsabilidad académica sobre el contenido, los resultados, las interpretaciones y las conclusiones corresponde exclusivamente a los integrantes del Grupo 5. El uso de herramientas computacionales y de inteligencia artificial se documenta en el Anexo A.

Referencias

Hofmann, H. (1994). *Statlog (German Credit Data)* [Dataset distribuido bajo licencia CC BY 4.0]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5NC77>

A Declaración de uso de inteligencia artificial

Durante el desarrollo del trabajo se utilizaron herramientas de inteligencia artificial generativa como apoyo para la organización, revisión y documentación del proyecto.

Su utilización se realizó bajo supervisión de los integrantes y no sustituyó la responsabilidad académica del grupo sobre los métodos, resultados, interpretaciones y conclusiones.

Usos realizados

Las herramientas de inteligencia artificial se emplearon principalmente para:

- proponer estructuras iniciales para organizar el notebook y el informe;
- revisar claridad, cohesión y estilo de algunos textos;
- sugerir explicaciones alternativas de conceptos estadísticos;
- apoyar la detección y corrección de errores de programación;
- proponer mejoras de presentación para tablas, figuras y código en Python y $\text{\LaTeX}$;
- elaborar listas de verificación para revisar la consistencia entre los distintos productos del trabajo.

Procedimiento de validación

Las sugerencias obtenidas mediante inteligencia artificial fueron revisadas antes de ser incorporadas. El procedimiento de control incluyó:

1. ejecutar y comprobar el código dentro del entorno del proyecto;
2. contrastar las cifras con las salidas reales del notebook;
3. revisar las fórmulas y los supuestos estadísticos;
4. eliminar afirmaciones no respaldadas por los datos;
5. distinguir asociación, predicción y causalidad;
6. adaptar la redacción al contenido efectivamente desarrollado por el grupo;
7. verificar la correspondencia entre el notebook, los archivos CSV, las figuras y el informe.

Responsabilidad académica

Las herramientas de inteligencia artificial no fueron consideradas fuentes de evidencia estadística ni sustitutos de la bibliografía, la documentación del dataset o las salidas computacionales.

Los integrantes del grupo asumen la responsabilidad sobre:

- la selección y aplicación de los métodos;
- la ejecución reproducible del notebook;
- la exactitud de las cifras presentadas;
- la interpretación de los coeficientes, intervalos y métricas;
- la identificación de las limitaciones;
- la redacción y defensa oral del trabajo.

Todo contenido incorporado al informe fue revisado y ajustado para mantener consistencia con los resultados obtenidos. Cuando una sugerencia no pudo verificarse mediante el código, los datos, la documentación o una fuente académica, no fue utilizada como fundamento de las conclusiones.

Alcance de la declaración

Esta declaración busca transparentar el uso de herramientas generativas sin atribuirles autoría ni responsabilidad sobre el trabajo. La autoría corresponde exclusivamente a los integrantes del Grupo 5:

- Armando Castro Chaupis;
- Henry Sánchez Alvarado;
- Alex Segura Núñez.

Conformidad de los integrantes

Mediante las firmas que se presentan a continuación, los integrantes declaran haber revisado el contenido del trabajo y confirman que el uso de herramientas de inteligencia artificial se realizó únicamente como apoyo para la organización, revisión y documentación del proyecto, bajo supervisión humana y sin sustituir la responsabilidad académica del grupo.

Las imágenes de las firmas se conservan únicamente en el entorno local de compilación y no forman parte del repositorio público.



Armando Castro Chaupis
Integrante del Grupo 5



Henry Sánchez Alvarado
Integrante del Grupo 5



Alex Segura Núñez
Integrante del Grupo 5

B Reproducibilidad

Este anexo resume las condiciones necesarias para reproducir el análisis estadístico, las tablas, las figuras y el informe. La fuente computacional principal del proyecto es:

`notebook/MCC002_Grupo5_Notebook.ipynb`

El notebook utiliza rutas relativas, fija las semillas de los procedimientos aleatorios y genera automáticamente los resultados almacenados en las carpetas `resultados/figuras` y `resultados/tablas`.

B.1 Entorno computacional

El análisis fue desarrollado en Windows 10 con Python 3.12.10. Las dependencias completas se registran en el archivo `requirements.txt`. Las principales versiones empleadas fueron:

Componente	Versión
Python	3.12.10
NumPy	2.4.6
pandas	3.0.3
SciPy	1.17.1
statsmodels	0.14.6
scikit-learn	1.9.0
seaborn	0.13.2

No se requiere una GPU. El análisis puede ejecutarse completamente en CPU.

B.2 Datos y configuración

El proyecto utiliza el conjunto *Statlog German Credit Data*. El notebook busca inicialmente:

`data/german.data`

Si el archivo no se encuentra disponible, se descarga desde el UCI Machine Learning Repository. Después de la carga se verifica que el conjunto contenga 1000 observaciones, 20 predictores y una variable de clase, sin valores faltantes ni filas completamente duplicadas.

La respuesta se recodifica como:

$$\text{mal crédito} = \begin{cases} 0, & \text{si la clase original es 1,} \\ 1, & \text{si la clase original es 2.} \end{cases}$$

La transformación produce 700 observaciones de buen riesgo y 300 de mal riesgo.

La semilla global utilizada es:

SEED = 2026.

Esta semilla controla el bootstrap, la partición de entrenamiento y prueba, la validación cruzada y el algoritmo Metropolis–Hastings.

B.3 Ejecución del notebook

Desde la raíz del repositorio, el entorno puede reconstruirse en PowerShell mediante:

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

El notebook puede ejecutarse desde Visual Studio Code mediante *Run All* o automáticamente con:

```
python -m jupyter nbconvert '
--to notebook '
--execute notebook/MCC002_Grupo5_Notebook.ipynb '
--output MCC002_Grupo5_Notebook_ejecutado.ipynb '
--output-dir notebook '
--ExecutePreprocessor.timeout=0
```

La ejecución debe finalizar sin excepciones y sin modificar manualmente las salidas entre celdas.

B.4 Resultados esperados

La ejecución completa debe generar:

- once figuras PNG en resultados/figuras;
- cuatro tablas CSV en resultados/tablas;
- las estimaciones, pruebas y métricas utilizadas en el informe.

Los principales valores de control son:

Control	Resultado esperado
Dimensiones del dataset	1000 × 21
Valores faltantes	0
Buenos créditos	700
Malos créditos	300
Tasa global de mal crédito	0.300
IC de Wilson del 95 %	[0.2724, 0.3291]
AUC en prueba	0.7740
AUC media en validación cruzada	0.7685
Costo con umbral 0.50	270
Costo con umbral 1/6	158
Aceptación de Metropolis–Hastings	25.68 %
Media posterior de duración	0.04084

Pueden presentarse pequeñas diferencias numéricas cuando se utilizan versiones distintas de las bibliotecas, pero las conclusiones y los valores redondeados deben mantenerse estables.

B.5 Compilación del informe

El informe se compila desde la carpeta `informe` mediante:

```
.\limpiar.ps1
.\compilar.ps1
```

El documento resultante debe generarse en:

`informe/build/main.pdf`

Después de la compilación debe verificarse:

`$LASTEXITCODE`

El valor esperado es 0. También debe comprobarse que no existan citas sin resolver, referencias mostradas como ?? ni errores fatales en `build/main.log`.

B.6 Criterio de reproducibilidad

El proyecto se considera reproducible porque utiliza rutas relativas, documenta las dependencias, fija las semillas, descarga o valida los datos, genera automáticamente sus artefactos y permite reconstruir el informe mediante scripts de compilación.

La reproducibilidad garantiza que los cálculos puedan repetirse bajo los mismos datos y supuestos. No implica que los resultados sean directamente generalizables a otras instituciones, periodos o poblaciones crediticias.